



**ESCUELA POLITÉCNICA
SUPERIOR DE CÓRDOBA**
Universidad de Córdoba



TRABAJO FIN DE GRADO
Grado en Ingeniería Informática

**Predicción de situaciones de baja visibilidad utilizando
métodos de clasificación ordinal**

Predicting low-visibility conditions using ordinal classification
methods

Autor: Jorge Cañete Ramírez
Directores: David Guijo Rubio
Pedro Antonio Gutiérrez Peña

junio, 2026



UNIVERSIDAD DE CÓRDOBA



Declaración de Originalidad

D./D.^a **Jorge Cañete Ramírez**
Estudiante del Grado en **Ingeniería Informática**

Con DNI [31024666N]

D E C L A R A:

Que es el autor y asume la originalidad, entendida esta última en el sentido de que no ha utilizado fuentes sin citarlas debidamente, del Trabajo Fin de Grado titulado:

Predicción de situaciones de baja visibilidad utilizando métodos de clasificación ordinal

Asimismo, es consciente de que el plagio, entendido como la presentación de un trabajo u obra hecho por otra persona como propio o la copia de textos sin citar su procedencia, conllevará automáticamente la calificación numérica de cero y que esta consecuencia se entiende sin perjuicio de las responsabilidades disciplinarias en las que pudieran incurrir si plagia, al tener la consideración de infracción muy grave, de conformidad con el artículo 11.g de la Ley 3/2022, de Convivencia Universitaria y artículo 8.g del Reglamento 5/2023 de Convivencia Universitaria de la Universidad de Córdoba.

En Córdoba, a 8 de Junio de 2026

El estudiante

Fdo.: _____
Jorge Cañete Ramírez

Sr./Sra. Director/a de Escuela Politécnica Superior de Córdoba.

Jorge Cañete Ramírez

- II -

Resumen

La visibilidad es un factor meteorológico crítico en la aviación, donde los eventos de niebla y baja visibilidad pueden comprometer gravemente la seguridad y operatividad de los vuelos. Dado que estos episodios son infrecuentes frente a las condiciones de cielo despejado, su predicción constituye un problema de clasificación altamente desbalanceado. Tradicionalmente, los modelos de aprendizaje automático abordan esta tarea desde un enfoque nominal, ignorando la naturaleza jerárquica de la visibilidad y penalizando por igual todos los errores.

Este Trabajo Fin de Grado propone el uso de métodos de clasificación ordinal para predecir situaciones de baja visibilidad en los aeropuertos de Santiago de Compostela y Vigo. Para ello, se integran datos de sensores locales (METAR), variables autorregresivas y datos de reanálisis climático (ERA5). Mediante un estudio de ablación y una evaluación rigurosa enfocada en la gravedad del error, se compara el rendimiento de modelos nominales de última generación frente a enfoques ordinales.

Los resultados demuestran empíricamente que, aunque los modelos nominales logran una mayor tasa de acierto global inflando los aciertos en cielos despejados, son vulnerables a cometer fallos catastróficos. Por el contrario, la metodología ordinal, sacrifica de forma controlada el acierto general para garantizar una reducción drástica de los peores errores predictivos, presentándose como la solución más robusta y segura para entornos de operatividad crítica como el control del tráfico aéreo.

Palabras clave: Clasificación ordinal, Predicción de niebla, Visibilidad en aeropuertos, Seguridad aérea, Aprendizaje automático, Datos desbalanceados.

Abstract

Visibility is a critical meteorological factor in aviation, where fog and low-visibility events can seriously compromise flight safety and operations. Since these events are rare compared to clear-sky conditions, predicting them constitutes a highly imbalanced classification problem. Traditionally, machine learning models have approached this task using a nominal approach, ignoring the hierarchical nature of visibility and penalizing all errors equally.

This Final Degree Project proposes the use of ordinal classification methods to predict low-visibility conditions at the airports in Santiago de Compostela and Vigo. To this end, data from local sensors (METAR), autoregressive variables, and climate reanalysis data (ERA5) are integrated. Through an ablation study and a rigorous evaluation focused on error severity, the performance of state-of-the-art nominal models is compared with that of ordinal approaches.

The results empirically demonstrate that, although nominal models achieve a higher overall accuracy rate by inflating the number of correct predictions under clear skies, they are vulnerable to catastrophic errors. In contrast, the ordinal methodology makes a controlled sacrifice of overall accuracy to ensure a drastic reduction in the worst predictive errors, presenting itself as the most robust and reliable solution for mission-critical environments such as air traffic control.

Keywords: Ordinal classification, Fog prediction, Airport visibility, Aviation safety, Machine learning, Imbalanced data.

Agradecimientos

Realizar este Trabajo de Fin de Grado representa el cierre de una etapa larga y muy dura, pero que me ha enseñado mucho. Al mirar atrás, soy consciente de que no hubiera podido llegar hasta aquí sin el apoyo de las personas que me rodean y que no me han dejado rendirme. Cada paso ha sido posible gracias a su apoyo y su paciencia. A todos ellos, gracias por ser mi impulso y mi refugio en los momentos más delicados.

A mis padres, por estar siempre ahí y apoyarme en todo lo que hago. Gracias por vuestro sacrificio y por la confianza incondicional que habéis depositado en mí para lograr este objetivo.

A mis amigos, por ayudarme a desconectar cuando más lo necesitaba y por acompañarme en los momentos difíciles durante estos años. Especialmente a mis “Marías” y Paula, por escucharme siempre y darme los ánimos y motivos necesarios para seguir adelante cuando yo no los encontraba. Sin vosotros, no hubiera llegado hasta aquí.

Por último, **a mis tutores**, David y Pedro. Gracias por facilitarme el camino desde el primer momento con la ayuda en la elección del tema. Especialmente a David, por su disponibilidad e implicación constante al resolver mis dudas, haciendo que todo este trayecto fuera mucho más sencillo.

Índice general

Declaración de Originalidad	I
Resumen	III
Abstract	V
Agradecimientos	VII
Índice de figuras	XI
Índice de tablas	XV
1. Introducción	1
2. Estado de la técnica	5
2.1. El problema de la visibilidad en la aviación y su modelado	5
2.2. Evolución del aprendizaje automático en la predicción de niebla	7
2.3. Los datos desbalanceados, el gran obstáculo	8
2.4. Fundamentos de la clasificación ordinal	9
2.5. Taxonomía de los métodos de clasificación ordinal	10
2.5.1. Enfoques ingenuos (naïve approaches)	11
2.5.2. Descomposiciones binarias ordinales	12
2.5.3. Modelos basados en umbrales	12
2.6. Métricas de evaluación	13
3. Formulación y objetivos	17
3.1. Formulación del problema	17
3.2. Objetivos	18
4. Metodología del trabajo	19
4.1. Enfoque metodológico y diseño del estudio	19
4.2. Entorno de desarrollo y herramientas	20
Trabajo Fin de Grado	- IX -

4.3.	Conjuntos de datos	21
4.3.1.	Adquisición de los datos	21
4.3.2.	Exploración y análisis de la variable objetivo	23
4.3.3.	Preprocesamiento e ingeniería de características	29
4.3.4.	Conjuntos de datos para la experimentación	30
4.3.5.	División de los datos	48
4.4.	Algoritmos y modelos empleados	50
4.4.1.	Modelos nominales de referencia	50
4.4.2.	Modelos de clasificación ordinal	51
5.	Desarrollo y experimentación	55
5.1.	Diseño del experimento	55
5.2.	Conjuntos de datos evaluados	56
5.3.	Modelos de aprendizaje automático evaluados	56
5.4.	Métricas de evaluación	58
6.	Resultados y discusión	61
6.1.	Análisis de resultados	61
6.1.1.	Resultados del conjunto de datos completo (Autorregresivos + sensores + ERA5)	61
6.1.2.	Estudio del impacto de las fuentes de datos	64
6.2.	Discusión de resultados	73
6.2.1.	Rendimiento global entre distintos escenarios	74
6.2.2.	Comparativa entre enfoques: nominal vs ordinal	76
6.2.3.	Estabilidad y fiabilidad ante la inicialización aleatoria	80
6.3.	Test estadísticos	87
6.3.1.	Evaluación del acierto puro (CCR y MS)	88
6.3.2.	Evaluación de la gravedad del error (AMAE y MMAE)	91
6.3.3.	Conclusión del análisis estadístico	94
7.	Conclusiones y recomendaciones	95
7.1.	Conclusiones	95
7.2.	Recomendaciones y trabajos futuros	97
	Bibliografía	99

Índice de figuras

2.1. Contraste visual de las condiciones operativas en la pista del aeropuerto de Vigo (LEVX) dependiendo de los eventos meteorológicos.	6
2.2. Taxonomía de los métodos de regresión y clasificación ordinal. (Fuente: [1])	10
4.1. Ubicación geográfica de los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX) dentro de la comunidad autónoma de Galicia. (Fuente: [2])	22
4.2. Comparativa de la distribución de la visibilidad por mes: LEST (arriba) y LEVX (abajo).	25
4.3. Comparativa de la distribución de la visibilidad por día de la semana entre LEST (arriba) y LEVX (abajo).	26
4.4. Comparativa de la evolución promedio de la visibilidad durante la semana entre LEST (arriba) y LEVX (abajo).	27
4.5. Comparativa de la distribución de la visibilidad por hora del día entre LEST (arriba) y LEVX (abajo).	28
4.6. Matriz de correlación cruzada (LEST - Solo Autorregresivos).	33
4.7. Correlación respecto a la visibilidad (LEST - Solo Autorregresivos).	34
4.8. Matriz de correlación cruzada (LEVX - Solo Autorregresivos).	35
4.9. Correlación respecto a la visibilidad (LEVX - Solo Autorregresivos).	36
4.10. Matriz de correlación cruzada (LEST - Solo METAR).	37
4.11. Correlación respecto a la visibilidad (LEST - Solo METAR).	38
4.12. Matriz de correlación cruzada (LEVX - Solo METAR).	39
4.13. Correlación respecto a la visibilidad (LEVX - Solo METAR).	40
4.14. Matriz de correlación cruzada (LEST - Solo ERA5).	41
4.15. Correlación respecto a la visibilidad (LEST - Solo ERA5).	42
4.16. Matriz de correlación cruzada (LEVX - Solo ERA5).	43
4.17. Correlación respecto a la visibilidad (LEVX - Solo ERA5).	44
4.18. Matriz de correlación cruzada (LEST - Conjunto completo).	45
4.19. Correlación respecto a la visibilidad (LEST - Conjunto completo).	46

4.20. Matriz de correlación cruzada (LEVX - Conjunto completo).	47
4.21. Correlación respecto a la visibilidad (LEVX - Conjunto completo). . .	48
6.1. Comparativa de matrices de confusión entre enfoques nominales y ordinales para el conjunto de datos completo.	64
6.2. Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos autorregresivos. . .	67
6.3. Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos de sensores (METAR).	70
6.4. Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos de reanálisis climático (ERA5).	73
6.5. Comparativa global de la distribución de la MS a través de todos los conjuntos de datos estudiados.	75
6.6. Comparativa global de la distribución del AMAE a través de todos los conjuntos de datos estudiados.	75
6.7. Comparativa global de la distribución del MMAE a través de todos los conjuntos de datos estudiados.	76
6.8. Comparativa directa de la MS entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos del estudio.	77
6.9. Comparativa directa del AMAE entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos del estudio.	79
6.10. Comparativa directa del MMAE entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos de estudio.	80
6.11. Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEST (Parte I).	82
6.11. Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEST (Parte II).	83
6.12. Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEVX (Parte I).	83
6.12. Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEVX (Parte II).	84
6.13. Comparativa pareada de 30 inicializaciones independientes entre NNPOM y LightGBM. (Continúa en la página siguiente)	86
6.13. Comparativa pareada de 30 inicializaciones independientes entre NNPOM y LightGBM. (Continuación)	87
6.14. Diagrama de Diferencia Crítica (CDD) para la métrica CCR.	88
6.15. Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en CCR.	89



6.16. Diagrama de Diferencia Crítica (CDD) para la métrica MS.	90
6.17. Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en MS.	91
6.18. Diagrama de Diferencia Crítica (CDD) para la métrica AMAE.	92
6.19. Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en AMAE.	92
6.20. Diagrama de Diferencia Crítica (CDD) para la métrica MMAE.	93
6.21. Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en MMAE.	94

Índice de tablas

1.1. Minutos acumulados en retrasos en las llegadas sobre el conjunto de los aeropuertos de Europa y España durante los años 2018, 2019 y 2020.	3
2.1. Ejemplo de diferentes matrices de costos para un problema de clasificación de cinco clases, con etiquetas de clase. $y \in \mathcal{Y} = \{C_1, C_2, C_3, C_4, C_5\}$. 11	11
4.1. Variables del conjunto de datos METAR	23
4.2. Variables del conjunto de datos ERA5	23
4.3. Número total de patrones por clase que ilustran el desequilibrio de datos en LEST y LEVX.	29
4.4. Resumen de las variables de entrada según el conjunto de datos evaluado.	31
4.5. Distribución de clases en el conjunto de entrenamiento (<i>Train set</i>). .	49
4.6. Distribución de clases en el conjunto de evaluación (<i>Test set</i>).	50
5.1. Espacio de búsqueda de hiperparámetros para los modelos evaluados. 58	58
6.1. Resultados obtenidos por los diferentes modelos utilizando el conjunto de datos completo (Sensores + Autorregresivos + ERA5).	62
6.2. Resultados obtenidos por los diferentes modelos utilizando solo datos autorregresivos.	66
6.3. Resultados obtenidos por los diferentes modelos utilizando únicamente los datos de sensores meteorológicos (METAR).	68
6.4. Resultados obtenidos por los diferentes modelos utilizando únicamente datos de reanálisis climático (ERA5).	72

Capítulo 1

Introducción

En la actualidad, los sistemas informáticos procesan y recopilan enormes cantidades de datos. A primera vista, gran cantidad de estos datos pueden parecer irrelevantes, pero si se analizan de una manera correcta, pueden proporcionar información valiosa. Este proceso se conoce como **minería de datos** [3]. Uno de los subcampos de la minería de datos con mayor proyección es el **aprendizaje automático** (*machine learning* [4], en inglés). Es en este subcampo donde nos vamos a centrar en la realización de este TFG.

El **aprendizaje automático** es una rama de la inteligencia artificial que proporciona mecanismos que permiten al ordenador aprender por sí mismo a resolver un determinado problema. Según la forma de obtención del conocimiento, el aprendizaje automático puede dividirse en distintos tipos:

- **Aprendizaje supervisado:** los patrones del conjunto de datos que se estudia cuentan con una etiqueta y, por tanto, el modelo se puede ajustar utilizando una serie de variables de entrada para predecir la variable de salida. Dependiendo de la naturaleza de esta variable, el aprendizaje supervisado se puede dividir principalmente en tres enfoques:
 - **Regresión:** se utiliza cuando el objetivo es predecir una variable de salida que está compuesta por uno o más valores continuos [5].
 - **Clasificación nominal:** se aplica cuando el modelo tiene como objetivo predecir etiquetas de clase que son categóricas, es decir, discretas y que no presenten ningún tipo de orden jerárquico entre ellas [3]. Por ejemplo, clasificar el estado del cielo en despejado, nublado o lluvioso.
 - **Clasificación ordinal:** se emplea cuando el objetivo es clasificar patrones en una escala categórica que muestra un orden natural entre las



CAPÍTULO 1. INTRODUCCIÓN

etiquetas [1]. Este es el enfoque central de este trabajo, ya que la visibilidad presenta niveles ordenados y la penalización de los errores varía según la distancia entre la clase predicha y la real.

- **Aprendizaje no supervisado:** los patrones del conjunto de datos que se estudia no cuentan con una etiqueta, es decir, el modelo a construir no utiliza ninguna información de la categoría o la clase a la que pertenecen los patrones, y, por tanto, esta tarea consiste en agrupar los patrones de acuerdo a una métrica que establece la similitud entre ellos [6].
- **Aprendizaje por refuerzo:** es un modelo de aprendizaje automático que se puede describir como “aprende haciendo” a través de una serie de experimentos de prueba y error [7].

En este proyecto se pretende abordar la tarea de predicción de la visibilidad en aeropuertos, centrándose en específico en los eventos de baja visibilidad producidos por la aparición de niebla. El objetivo es aportar un sistema de apoyo a la decisión del personal experto para anticiparse a situaciones de riesgo en procesos de despegue o aterrizaje con el objetivo de reducir riesgos y costes. Para ello se van a considerar datos de variables meteorológicas como entrada, entre las cuales destacan la velocidad y dirección del viento, la presión atmosférica o la temperatura. La variable objetivo a predecir es la distancia en metros en la que hay visibilidad.

La visibilidad es un factor fundamental en la aviación, ya que influye directamente en la seguridad y operatividad de los vuelos. Una visibilidad reducida puede dificultar al piloto las maniobras de aterrizaje y despegue, aumentar el riesgo de incidentes y por consecuencia, provocar retrasos o cancelaciones. Por otro lado, las falsas alarmas, es decir, cuando se indica que habrá baja visibilidad cuando realmente no es así puede conllevar enormes pérdidas económicas por el uso adicional de combustible al tener que realizar desvíos, o por las indemnizaciones a pasajeros. Según datos de organizaciones como Eurocontrol [8], la meteorología adversa es una de las principales causas de interrupción en el espacio aéreo. Prueba de ello lo podemos ver en la Tabla 1.1 que muestra los minutos acumulados en retrasos en las llegadas sobre el conjunto de los aeropuertos de Europa y España durante los años 2018, 2019 y 2020. Entorno a un 40-60 % de los minutos de retraso acumulados cada año son provocados por causas meteorológicas.



CAPÍTULO 1. INTRODUCCIÓN

Tabla 1.1: Minutos acumulados en retrasos en las llegadas sobre el conjunto de los aeropuertos de Europa y España durante los años 2018, 2019 y 2020.

Año	Minutos acumulados en retrasos	Minutos acumulados por retrasos causados por eventos meteorológicos
Aeropuertos de Europa		
2018	3.109,728	1.537.449 (49,44 %)
2019	2.795.172	1.189.345 (42,55 %)
2020	664.015	450.069 (67,78 %)
Aeropuertos de España		
2018	568.857	324.191 (56,99 %)
2019	314.328	147.545 (46,94 %)
2020	59.729	31.728 (53,12 %)

Desde el punto de vista del modelado computacional, los eventos de niebla y baja visibilidad son, por lo general, eventos más raros, lo que significa que pueden considerarse similares a eventos extremos [9]. Por tanto, si el problema se aborda como una tarea de clasificación, las clases asociadas a la baja visibilidad contendrán muchos menos ejemplos que las situaciones despejadas, dando lugar a un problema de clasificación con datos altamente desbalanceados [10].

Los problemas de clasificación ordinal [1] son aquellos problemas de aprendizaje supervisado en los que el objetivo es clasificar patrones en una escala categórica que muestra un orden natural entre las etiquetas. Muchas aplicaciones del mundo real presentan esta estructura de etiquetado; algunos ejemplos destacados incluyen el diagnóstico médico y la clasificación del riesgo de enfermedades [11] o la estimación de la edad facial mediante escalas de valoración [12]. Esta variedad de dominios ha ido incrementando el número de métodos y algoritmos desarrollados en los últimos años en este campo. Aunque la clasificación ordinal puede afrontarse utilizando técnicas estándar de clasificación nominal, existen varios algoritmos que pueden beneficiarse específicamente de la información de ordenación.

La principal ventaja de este enfoque es que asume que los costes de los errores de clasificación varían según la distancia entre la clase predicha y la real en la escala ordinal. Por ejemplo, en un entorno de un aeropuerto, confundir una situación de niebla con una situación despejada debe estar mucho más penalizado que confundirla con una simple neblina.

Este proyecto tiene como objetivo desarrollar un modelo basado en aprendizaje



CAPÍTULO 1. INTRODUCCIÓN

automático para predecir la visibilidad en los aeropuertos de Santiago de Compostela y Vigo. Para ello, se utilizarán registros históricos obtenidos en los últimos años de sensores meteorológicos que contienen información sobre variables como temperatura, humedad y velocidad del viento, entre otras. Estos conjuntos de datos se tratan de datos METAR [13] que serán proporcionados por el grupo de investigación “Aprendizaje y Redes Neuronales Artificiales” (AYRNA) [14], por lo que el proyecto se centrará en demostrar la eficacia de la clasificación ordinal en este tipo de problemas.

Capítulo 2

Estado de la técnica


2.1. El problema de la visibilidad en la aviación y su modelado

La visibilidad es un factor meteorológico crítico para la aviación, ya que compromete de manera directa la seguridad y eficiencia de los vuelos. Los eventos de baja visibilidad provocados por la formación de niebla representan una de las mayores restricciones para el tráfico aéreo, dificultando drásticamente las maniobras en las pistas del aeropuerto. Cuando las condiciones caen por debajo de los mínimos establecidos las operaciones pueden verse restringidas o incluso suspendidas, lo que genera desde retrasos y desvíos hacia aeropuertos alternativos hasta la cancelación total de los vuelos [15]. En las últimas décadas, el impacto logístico y económico de estos eventos ha crecido sustancialmente debido al aumento del tráfico aéreo mundial, llegando a provocar unos costes financieros comparables a los generados por otras condiciones meteorológicas extremas, como las grandes tormentas [16]. Para mitigar estos riesgos y garantizar la seguridad de los vuelos y sus pasajeros y personal, es de una importancia vital disponer de pronósticos precisos que anticipen los episodios de baja visibilidad.

Históricamente, la estimación de la visibilidad y la niebla se ha abordado utilizando sistemas de Predicción Numérica del Tiempo (NWP, del inglés, *Numerical Weather Prediction*). A pesar de los importantes avances desarrollados en la resolución de estos modelos a lo largo del tiempo, todavía, predecir con exactitud el ciclo de vida de la niebla sigue siendo un enorme desafío para la tecnología. A lo largo de los años se ha demostrado que los modelos NWP suelen presentar amplios sesgos a la hora de predecir el inicio y la disipación de la niebla, así como su profundidad o su contenido de agua líquida [17]. El principal motivo de esta limitación radica

en que la formación y disipación de la niebla dependen de un equilibrio complejo entre múltiples procesos físicos a muy pequeña escala [17]. Debido a esta naturaleza altamente local, los modelos numéricos tradicionales tienen serias dificultades para representar estos mecanismos de manera precisa mediante simulaciones a gran escala.

Precisamente debido a las limitaciones que presentan los modelos NWP para capturar la naturaleza local de la niebla, durante los últimos años se ha desarrollado un interés masivo por explorar enfoques alternativos por parte de la comunidad investigadora [16]. Aquí es donde irrumpen las técnicas basadas en Inteligencia Artificial (IA) y Aprendizaje Automático (*Machine Learning*). Estos algoritmos avanzados ofrecen una enorme capacidad para procesar diferentes tipos de variables meteorológicas medidas, salidas de modelos numéricos y series temporales, superando las deficiencias físicas mediante el modelado directo de los datos [2]. La aplicación de estos algoritmos suponen una vía más moderna para la creación de modelos mucho más robustos, capaces de ofrecer pronósticos más precisos sobre la reducción de la visibilidad adaptándose a las condiciones locales de cada entorno aeroportuario. Como prueba de ello, la literatura científica reciente ofrece numerosos casos de éxito, como por ejemplo, el trabajo de Cornejo-Bueno *et al.* [18], quienes demostraron la superioridad de las técnicas de aprendizaje automático frente a modelos clásicos para eventos de niebla en aeropuertos españoles, o las aproximaciones basadas en aprendizaje profundo (*Deep Learning*) propuestas por Zhu *et al.* [19] para la predicción de rangos de visibilidad en aeropuertos internacionales.



(a) Visibilidad despejada en el aeropuerto de Vigo.



(b) Visibilidad severamente reducida por niebla en el aeropuerto de Vigo.

Figura 2.1: Contraste visual de las condiciones operativas en la pista del aeropuerto de Vigo (LEVX) dependiendo de los eventos meteorológicos.



2.2. Evolución del aprendizaje automático en la predicción de niebla

El uso de técnicas de Aprendizaje Automático (ML, del inglés, *Machine Learning*) para la predicción de la niebla y eventos de baja visibilidad ha experimentado una gran evolución a lo largo de las últimas décadas, pasando de modelos estadísticos simples a modelos más complejos de aprendizaje profundo. El primer intento documentado de aplicar este tipo de metodologías a la predicción de niebla se remonta al año 1983, cuando se propuso un esquema basado en regresión lineal múltiple (MOS, del inglés, *Model Output Statistics*) para estimar las probabilidades de aparición de niebla marina [20]. Posteriormente, durante los 90, la investigación se centró en algoritmos más avanzados como los enfoques de árboles de decisión (específicamente el algoritmo C4.5), los cuales se utilizaron para extraer reglas de clasificación concretas sobre la ocurrencia de la niebla a partir de datos de boyas y observaciones marítimas [21].

Con el aumento de la capacidad computacional en la década de los 2000, los modelos predictivos comenzaron a sofisticarse y a centrarse en el ámbito aeronáutico. Un hito destacable ocurrió en 2007, cuando se aplicaron las Redes Neuronales Artificiales (ANNs, del inglés, *Artificial Neural Network*) utilizando una base de datos de 44 años de observaciones meteorológicas para proporcionar pronósticos precisos de niebla en el Aeropuerto Internacional de Canberra [22]. Ese mismo año, se desarrollaron también hasta 39 redes neuronales distintas para predecir el techo de nubes y la visibilidad en diversos aeródromos del noroeste de Estados Unidos, demostrando una superioridad clara frente a las técnicas de regresión logística estándar y el sistema MOS [23]. En la siguiente década, se introdujeron enfoques variados, como sistemas basados en la lógica difusa para hacer frente a la imprecisión de la predicción NWP, y métodos de regresión de aprendizaje automático, como las Máquinas de Vectores Soporte (SVM, del inglés, *Support Vector Machine*) o las *Extreme Learning Machines* [2], probadas con éxito para predecir eventos de baja visibilidad por niebla de radiación en el aeropuerto de Valladolid [18].

El verdadero punto de inflexión en este campo se ha producido en los últimos años. Las primeras incursiones serias del Aprendizaje Profundo (DL, del inglés, *Deep Learning*) en este campo se reportaron hacia el año 2017, cuando se empezaron a usar redes neuronales profundas para predecir rangos de visibilidad en grandes aeropuertos internacionales [19]. Desde 2020 en adelante, la aplicación de estos modelos de *Deep Learning* y *Machine Learning* para este ámbito ha sido masiva. En la actualidad, para la creación de modelos para este tema dominan dos grandes



bloques algorítmicos: por un lado, los enfoques basados en árboles (XGBoost [24] o LightGBM [25]) debido a su robustez y precisión; y por otro, las redes neuronales profundas (CNN, del inglés, *Convolutional Neural Network* [26], o LSTM, del inglés, *Long Short-Term Memory* [27]), capaces de procesar relaciones complejas no lineales en series temporales meteorológicas [2].

2.3. Los datos desbalanceados, el gran obstáculo

Uno de los mayores desafíos al aplicar técnicas de ML en la predicción de fenómenos meteorológicos extremos, como la baja visibilidad, es el desbalanceo natural de los datos. En climatología, las condiciones de visibilidad reducida son eventos poco frecuentes (clase minoritaria) en comparación con las horas de cielos despejados o visibilidad normal (clase mayoritaria).

Este desbalanceo de clases provoca que los modelos predictivos tradicionales tiendan a sesgarse hacia la clase mayoritaria, logrando una alta precisión global estadística pero fallando a la hora de predecir correctamente los eventos críticos de baja visibilidad, que son precisamente los de mayor interés para la seguridad aérea.

Diferentes autores han destacado este problema intrínseco en la literatura. Por ejemplo, Castillo-Botón et al. [28] señalan que predecir eventos de niebla mediante modelos de aprendizaje automático requiere tratar cuidadosamente la falta de ejemplos de visibilidad baja frente a la abrumadora cantidad de casos de visibilidad despejada. De manera similar, estudios recientes como el de Teeloku et al. [29] observan que, dependiendo de la localización geográfica, los eventos de niebla suelen representar apenas entre el 10 % y el 12 % del total de los registros. Esta proporción constituye un caso evidente de datos desbalanceados que obliga a la comunidad científica a aplicar técnicas de remuestreo o ajuste de pesos en las clases.

Además, enfoques recientes para predecir la baja visibilidad [30] han enfatizado que el uso de datos históricos convencionales sin un tratamiento específico de este desbalanceo dificulta enormemente la construcción de sistemas de alerta temprana fiables.

En conclusión, el problema de los datos desbalanceados no es una particularidad de un caso de uso aislado, sino una barrera intrínseca y generalizada en el dominio de la meteorología. Esta dificultad justifica la necesidad de explorar enfoques más avanzados que sean robustos frente a distribuciones asimétricas, motivando así la aplicación de la clasificación ordinal que se aborda en este trabajo para mitigar

dichos efectos.

2.4. Fundamentos de la clasificación ordinal

La clasificación ordinal engloba a un conjunto de técnicas de aprendizaje automático cuyo objetivo es predecir y clasificar patrones en una escala categórica que presenta un orden natural entre sus etiquetas. Desde un punto de vista conceptual, los problemas de clasificación ordinal se sitúan a medio camino entre la clasificación y la regresión. A diferencia de la regresión estándar, donde la variable a predecir es un valor continuo en el conjunto de los números reales, las etiquetas en la clasificación ordinal sirven como un indicador cualitativo del patrón en lugar de uno puramente cuantitativo, ya que no se asume una distancia métrica fija entre las distintas categorías [1].

En términos matemáticos, un problema de clasificación ordinal consiste en predecir una etiqueta y asociada a un vector de características de entrada $\mathbf{x}$ (con $\mathbf{x} \in X \subseteq \mathbb{R}^k$, siendo k la dimensión del espacio de entrada). Esta etiqueta pertenece a un conjunto finito de clases $Y = \{\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_Q\}$. La característica que define más esta técnica es que se impone una relación de orden estricta y natural entre las clases, la cual se expresa matemáticamente como $\mathcal{C}_1 \prec \mathcal{C}_2 \prec \dots \prec \mathcal{C}_Q$, donde el símbolo $\prec$ denota dicha relación de orden. Esto permite que dos elementos cualesquiera del conjunto Y puedan ser comparados de forma jerárquica, algo que resulta imposible bajo un enfoque de clasificación nominal multiclase.

El hecho de incorporar esta información de orden resulta decisivo a la hora de modelar el problema por una razón fundamental: el coste de los errores de clasificación no es el mismo. En el ámbito de la meteorología aeronáutica y la predicción de visibilidad que se aborda en este trabajo, predecir erróneamente un evento de “visibilidad despejada” cuando en realidad hay “visibilidad extremadamente baja” (un error situado en los extremos opuestos de la escala ordinal) debe penalizarse de manera mucho más severa que confundir “visibilidad extremadamente baja” con “visibilidad baja” (un error entre categorías adyacentes). Mientras que los algoritmos nominales estándar ignoran esta topología y tratan todos los fallos por igual, los métodos de clasificación ordinal asumen que los costes por clasificación errónea varían drásticamente. Al penalizar las predicciones en función de la distancia entre la categoría real y la predicha en la escala ordinal, se logra construir modelos predictivos muchos más precisos y adaptados a la realidad del problema [1].

2.5. Taxonomía de los métodos de clasificación ordinal

Dado el aumento del uso de la clasificación ordinal en múltiples disciplinas, se ha ido estableciendo una taxonomía general que categoriza estos algoritmos en función de como se construye el modelo para tener en cuenta (o ignorar) la información del orden. Las diferentes metodologías se agrupan en tres familias: enfoques ingenuos (Naïve approaches), descomposiciones binarias ordinales y modelos basados en umbrales [1].

Como se ilustra en la Figura 2.2, propuesta en el estudio de Gutiérrez *et al.* [1], las diferentes metodologías se agrupan de la forma comentada anteriormente.




Figura 2.2: Taxonomía de los métodos de regresión y clasificación ordinal. (Fuente: [1])

A continuación, se detallan las características fundamentales de cada una de estas familias algorítmicas y los modelos que las componen.

2.5.1. Enfoques ingenuos (naïve approaches)

Este primer grupo engloba aquellas técnicas que simplifican el problema ordinal transformándolo en otro paradigma de aprendizaje estándar. Dentro de este grupo destacan:

- **Regresión:** mapea las categorías a valores numéricos reales (por ejemplo, asignando a la escala ordinal valores como $1, 2, \dots, Q$) y aplica algoritmos de regresión estándar. Algunos enfoques clásicos como el propuesto por Kramer (2001) [31] emplean esta técnica mapeando la escala ordinal asignando valores numéricos a las clases para entrenar un modelo de árboles de regresión. El principal inconveniente que presenta es que asume a priori una distancia métrica fija entre las clases, algo que no suele cumplirse en la realidad.
- **Clasificación nominal:** ignora por completo el orden natural de las etiquetas y aborda el problema como una clasificación multiclase estándar. Como ya se ha indicado anteriormente, esto supone una pérdida de información muy importante, lo que hace que requiera de más datos de entrenamiento [32].
- **Clasificación sensible al coste:** trata de mitigar los errores asignando diferentes pesos a las clasificaciones erróneas mediante matrices de coste. A modo de ilustración, la Tabla 2.1 muestra un ejemplo de tres matrices de coste principales (cero-uno, absoluto y cuadrático) para un problema de clasificación con cinco categorías [1]. Mientras que la clasificación nominal asume una matriz “cero-uno” que penaliza todos los errores por igual, los enfoques ordinales emplean costes absolutos o cuadráticos. Como se demuestra en los estudios de Kotsiantis y Pintelas (2004) [33], la aplicación de estos costes de clasificación errónea fijos y desiguales minimiza de forma efectiva la distancia entre las categorías reales y predichas, mejorando el rendimiento ordinal sin perjudicar la exactitud global de los modelos.

Tabla 2.1: Ejemplo de diferentes matrices de costos para un problema de clasificación de cinco clases, con etiquetas de clase. $y \in \mathcal{Y} = \{\mathcal{C}_1, \mathcal{C}_2, \mathcal{C}_3, \mathcal{C}_4, \mathcal{C}_5\}$.

Cero-uno	Coste absoluto	Coste cuadrático
$\begin{pmatrix} 0 & 1 & 1 & 1 & 1 \\ 1 & 0 & 1 & 1 & 1 \\ 1 & 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 1 & 0 \end{pmatrix}$	$\begin{pmatrix} 0 & 1 & 2 & 3 & 4 \\ 1 & 0 & 1 & 2 & 3 \\ 2 & 1 & 0 & 1 & 2 \\ 3 & 2 & 1 & 0 & 1 \\ 4 & 3 & 2 & 1 & 0 \end{pmatrix}$	$\begin{pmatrix} 0 & 1 & 4 & 9 & 16 \\ 1 & 0 & 1 & 4 & 9 \\ 4 & 1 & 0 & 1 & 4 \\ 9 & 4 & 1 & 0 & 1 \\ 16 & 9 & 4 & 1 & 0 \end{pmatrix}$

Las etiquetas de clase reales están dispuestas en filas, mientras que las etiquetas de clase predichas están dispuestas en columnas.



2.5.2. Descomposiciones binarias ordinales

La idea central de este grupo consiste en descomponer la variable objetivo ordinal en múltiples subproblemas de clasificación binaria más sencillos. En lugar de predecir la clase directamente, el modelo formula preguntas lógicas del tipo: “¿Es la etiqueta del patrón x mayor que q ?” [34]. Dependiendo de su arquitectura, estos enfoques se dividen en dos vertientes: los de **múltiples modelos**, donde se entrena un clasificador binario independiente para cada subproblema. Frank y Hall (2001) [35], utilizaron este esquema (denominado *OrderedPartitions*) para resolver los subproblemas mediante árboles de decisión independientes. Por otro lado, existen los enfoques de **modelo único de múltiples salidas**, como las redes neuronales adaptadas, en las que una sola estructura computacional se encarga de resolver todos los subproblemas binarios simultáneamente mediante esquemas de codificación de objetivos.

2.5.3. Modelos basados en umbrales

Este último grupo agrupa a los enfoques más populares y robustos para modelar problemas ordinales. Estos métodos asumen que existe una variable continua no observable (latente) que subyace a la respuesta ordinal [36]. Históricamente, esta idea tiene sus raíces estadísticas en el Modelo de Probabilidades Proporcionales (POM) introducido por McCullagh en 1980 [37]. El funcionamiento de estos algoritmos se basa en dos pilares: primero, estiman una función $f(x)$ que mapea el espacio de entrada a un espacio real unidimensional; y segundo, calculan un conjunto de umbrales ordenados $b = (b_1, b_2, \dots, b_{Q-1})$ que dividen esa recta real en distintos intervalos [1].

El modelo impone la restricción matemática estricta de que $b_1 \leq b_2 \leq \dots \leq b_{Q-1}$ indicándonos de este modo que cada región separada por dos umbrales consecutivos corresponde a una categoría específica en la escala ordinal. A este grupo pertenecen modelos estadísticos clásicos, así como las Máquinas de Vectores de Soporte Ordinales (SVOR), con formulaciones destacadas como las que proponen Chu y Keerthi (2007) [38]. Precisamente, variantes basadas en umbrales como el enfoque *Logistic All-Threshold* (LAT) destacan en la actualidad por considerar la jerarquía ordinal completa junto con todos los umbrales para el cálculo de probabilidades, siendo algoritmos altamente interpretables y especialmente aptos para problemas como el que se nos presenta en este trabajo, la predicción de visibilidad.

Partiendo de este fundamento centrado en la proyección sobre una variable latente continua y la delimitación mediante umbrales, la literatura recogida en esta taxonomía [1] ha desarrollado diversas familias algorítmicas fundamentales:



- **Modelos de enlace acumulativo (*Cumulative Link Models*)**: constituyen las extensiones estadísticas clásicas de los modelos lineales (como el POM), los cuales emplean funciones de enlace para modelar las probabilidades acumuladas de pertenencia a las distintas categorías.
- **Máquinas de Vectores de Soporte (*Support Vector Machines*)**: adaptaciones del paradigma SVM tradicional (como SVOR) que formulan el problema optimizando múltiples hiperplanos paralelos que actúan como umbrales, maximizando el margen de separación entre clases contiguas.
- **Aprendizaje discriminante (*Discriminant Learning*)**: enfoques como KDLOP que buscan proyecciones (lineales o mediante funciones kernel) en un subespacio donde las clases mantengan estrictamente su orden natural, maximizando la separación interclase.
- **Aprendizaje basado en Perceptrón (*Perceptron Learning*)**: algoritmos basados en el perceptrón clásico modificados para actualizar de forma dinámica e incremental un vector de pesos y un conjunto de umbrales mediante reglas de aprendizaje en línea (*online learning*).
- **Clasificación binaria aumentada (*Augmented Binary Classification*)**: métodos que transforman el problema duplicando o expandiendo el espacio de características original, permitiendo que un único clasificador binario estándar aprenda de manera simultánea la estructura jerárquica de todos los umbrales del problema ordinal.
- **Métodos de ensamble (*Ensembles*)**: combinaciones de múltiples clasificadores ordinales débiles basados en umbrales (como árboles de decisión ordinales) para construir un modelo predictivo global mucho más robusto frente al sobreentrenamiento.
- **Procesos Gaussianos (*Gaussian Processes*)**: modelos no paramétricos bajo un enfoque bayesiano que definen distribuciones a priori sobre la función latente, lo que les permite capturar relaciones no lineales complejas y proporcionar de forma nativa una estimación de la incertidumbre en la predicción.

2.6. Métricas de evaluación

En este ámbito de la predicción de la visibilidad mediante clasificación ordinal, y especialmente ante escenarios con un notable desbalanceo de clases, la evaluación del rendimiento de los distintos modelos constituye un desafío en si mismo. Tradicionalmente, los modelos de aprendizaje automático se evalúan mediante métricas

nominales como la tasa de acierto global. Sin embargo, en problemas ordinales estas métricas resultan insuficientes y potencialmente engañosas, ya que asumen una matriz de coste “cero-uno” y no penalizan la distancia real entre la clase predicha y la observada [1, 2].

Por tanto, para obtener una evaluación rigurosa y completa, en la fase de experimentación de este trabajo se utilizará una combinación de métricas nominales y métricas diseñadas específicamente para la ordinalidad:

■ **Métricas nominales (no consideran la distancia entre clases)**

- ***Correct Classification Rate (CCR)***: es la tasa de acierto global del modelo. Al ser una métrica nominal, no tiene en cuenta la estructura ordinal del problema de clasificación a resolver, por lo que debe interpretarse con cautela, ya que puede sobreestimar el rendimiento cuando los errores ocurren a grandes distancias en la escala ordinal [39].

$$CCR = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i) \quad (2.1)$$

- ***Mean Zero-one Error (MZE)***: representa la tasa de error global del clasificador. Considera una pérdida estricta de “cero-uno” para las clasificaciones erróneas, evaluando el rendimiento general sin tener en cuenta el orden natural de las etiquetas. Es el negativo del CCR (se calcula como 1 - CCR) [1].

$$MZE = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(y_i \neq \hat{y}_i) = 1 - CCR \quad (2.2)$$

- ***Minimum Sensitivity (MS)***: evalúa el rendimiento específico sobre la clase con peor tasa de acierto. Resulta fundamental en conjuntos de datos desbalanceados para identificar si el modelo está ignorando a las clases minoritarias (como los eventos de niebla densa) para favorecer a la clase mayoritaria [40].

$$MS = \min \langle S_j = \frac{O_{jj}}{O_{j\bullet}}; j = 1, \dots, J \rangle \in [0, 1] \quad (2.3)$$

- ***Balanced Accuracy (BA)***: es la tasa de acierto (CCR) ajustada y ponderada según la distribución real de las clases. Esta métrica permite demostrar si el clasificador ofrece un rendimiento de predicción equitativo en todas las categorías del problema [41].

$$BA = \frac{\sum_{j=1}^J \frac{O_{jj}}{O_{j\bullet}}}{J} \in [0, 1] \quad (2.4)$$

■ **Métricas ordinales (penalizan el error basándose en distancia):**

- **Mean Absolute Error (MAE):** mide la desviación media en valor absoluto entre la categoría predicha y la categoría real. Sus valores oscilan entre 0 y la máxima desviación posible en número de clases [42].

$$MAE = \frac{1}{N} \sum_{i=1}^N |\mathcal{O}(y_i) - \mathcal{O}(y_i^*)| \quad (2.5)$$

- **Average Mean Absolute Error (AMAE):** representa el promedio de los errores absolutos medios (MAEs) calculados de forma independiente para cada una de las clases. Es una métrica de minimización especialmente robusta para tratar el desbalanceo en problemas ordinales [43].

$$AMAE = \frac{1}{J} \sum_{j=1}^J \frac{1}{N_j} \sum_{i=1}^{N_j} |\mathcal{O}(y_i) - \mathcal{O}(\hat{y}_i)| \in [0, J - 1] \quad (2.6)$$

- **Maximum Mean Absolute Error (MMAE):** corresponde al valor máximo de los MAE obtenidos entre todas las clases. Es decir, cuantifica cuál es el error absoluto de aquella clase que presenta el peor desempeño en el modelo [44].

$$MMAE = \max\{MAE_j; j = 1, \dots, J\} \in [0, J - 1]. \quad (2.7)$$

- **Quadratic Weighted Kappa (QWK):** es un coeficiente que penaliza las clasificaciones erróneas de manera proporcional a la distancia cuadrática entre la clase predicha y la clase real en la escala ordinal. Ofrece una evaluación altamente precisa del rendimiento del clasificador respetando el orden natural del problema [45].

$$QWK = 1 - \frac{\sum_{i=1}^N \sum_{j=1}^N \omega_{ij} O_{ij}}{\sum_{i=1}^N \sum_{j=1}^N \omega_{ij} E_{ij}} \in [-1, 1] \quad (2.8)$$

Capítulo 3

Formulación del problema y objetivos

3.1. Formulación del problema

El problema central que aborda este trabajo radica en la dificultad de predecir con precisión los episodios de baja visibilidad y niebla en el ámbito aeroportuario, concretamente en los aeropuertos de Santiago de Compostela (bajo el código METAR, del inglés, *Meteorological Aerodrome Reports*, LEST) y Vigo (bajo el código METAR, LEVX). Como se ha expuesto en el Capítulo 2, la visibilidad es un factor crítico en el ámbito de la aviación que influye directamente en la seguridad y operatividad de los vuelos.

Desde el punto de vista del aprendizaje automático, la predicción de esta variable meteorológica a partir de registros estandarizados (METAR) presenta dos grandes desafíos: en primer lugar, los eventos de baja visibilidad extrema son fenómenos meteorológicos raros, lo que genera conjuntos de datos de entrenamiento severamente desbalanceados a favor de las condiciones de cielo despejado; en segundo lugar, las categorías de visibilidad a predecir presentan un orden natural estricto fundamentado en la gravedad de la restricción visual, donde, por ejemplo, existe una jerarquía lógica tal que: visibilidad extremadamente baja < visibilidad baja < visibilidad aceptable < visibilidad despejada.

Al enfrentarse a este problema, los modelos de clasificación nominal estándar resultan ineficaces, ya que tienden a sesgar sus predicciones hacia la clase mayoritaria e ignoran por completo la tipología ordinal de las etiquetas, asumiendo que todos los errores de predicción provocan el mismo coste operativo. Por consiguiente, el problema específico que se pretende resolver en este trabajo consiste en **demostrar**

la eficacia de la clasificación ordinal a la hora de predecir la visibilidad en aeropuertos a partir de datos meteorológicos, en concreto, en los de Santiago de Compostela y Vigo.

3.2. Objetivos

El objetivo principal de este proyecto es demostrar que la clasificación ordinal es eficaz para resolver problemas de predicción de visibilidad en aeropuertos a partir de datos meteorológicos. Los principales objetivos a destacar de este trabajo son los siguientes:

- Realizar un estudio teórico sobre la clasificación ordinal, explorando su fundamentación matemática y aplicaciones en problemas similares de predicción de eventos atmosféricos.
- Obtener y preprocesar los datos de sensores meteorológicos de los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX), asegurando su limpieza y transformación adecuada para la modelización.
- Identificar las variables meteorológicas más influyentes en la predicción de la visibilidad.
- Implementar y evaluar distintos métodos de clasificación ordinal, incluyendo algoritmos tradicionales y adaptaciones específicas para este tipo de problemas.
- Extraer conclusiones sobre la aplicabilidad de la clasificación ordinal en este tipo de problemas.

Capítulo 4

Metodología del trabajo

En este capítulo se detalla el enfoque metodológico llevado a cabo para tratar de resolver este problema de la precisión de situaciones de baja visibilidad. A lo largo de cada sección se detallarán las fases realizadas durante el proyecto.

4.1. Enfoque metodológico y diseño del estudio

Esta investigación sigue un enfoque empírico y experimental de carácter cuantitativo. El diseño del estudio se basa en el entrenamiento, validación y evaluación de diversos modelos predictivos supervisados.

El objetivo metodológico principal es establecer una comparativa rigurosa entre los modelos de clasificación nominal tradicionales, que actuarán como *baselines*, y modelos específicos de clasificación ordinal. Esto nos permitirá demostrar empíricamente si la inclusión de la información (orden natural de las etiquetas de visibilidad) aporta una mejora significativa en el rendimiento y en la reducción de errores que puedan ser críticos en el ámbito de la aviación.

Para garantizar la solidez y validez del estudio, la experimentación se lleva a cabo sobre dos conjuntos de datos independientes correspondientes a los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX). La utilización de estos dos aeropuertos nos permite evaluar la capacidad de generalización de los modelos desarrollados y comprobar su eficacia frente a las condiciones climáticas particulares y a la orografía de cada zona geográfica de estos aeropuertos. Todo el proceso de la experimentación se ha diseñado buscando la reproducibilidad, controlando las variables aleatorias y evaluando los modelos bajo un esquema estricto de validación cruzada temporal.

4.2. Entorno de desarrollo y herramientas

Para la realización de este trabajo, se ha configurado un entorno de desarrollo basado en el lenguaje de programación **Python** [46]. La elección de este lenguaje responde a su capacidad para integrar herramientas de análisis de datos y aprendizaje automático.

El ecosistema de herramientas utilizado se divide en las siguientes categorías:

- **Gestión y manipulación de datos:** para el preprocesamiento de la información se trabaja con librerías esenciales como **Pandas** [47] y **NumPy** [48], que permiten la manipulación eficiente de estructuras tabulares y operaciones matriciales. Además, se emplea de forma auxiliar la librería **skforecast** [49] para la extracción automatizada de variables autorregresivas a partir de las series temporales históricas.
- **Modelado y aprendizaje automático:** además de **scikit-learn** [50] como núcleo principal para la validación cruzada y evaluación estadística, se han incorporado frameworks de alto rendimiento. Destaca el uso de **LightGBM** [25, 51] como algoritmo base altamente optimizado basado en *gradient boosting*.
- **Herramientas de referencia en clasificación ordinal:** en el ámbito de la investigación sobre clasificación ordinal, hay tres librerías que representan el estado del arte en la implementación de estos algoritmos:
 - **ORCA (*Ordinal Regression and Classification Algorithms*)** [52]: desarrollado por el grupo AYRNA [14], este framework es un referente en la experimentación con métodos de descomposición binaria y modelos basados en umbrales. Es altamente valorado en el ámbito académico por su capacidad de comparativa entre algoritmos y conjuntos de datos.
 - **skordinal** [53]: es una extensión diseñada para integrar clasificadores ordinales dentro del flujo de trabajo estándar de **scikit-learn**. Representa una evolución hacia la integración de algoritmos complejos de clasificación ordinal en entornos Python.
 - **mord** [54]: esta librería se posiciona como una herramienta versátil para el despliegue de soluciones de clasificación ordinal, clasificando los modelos de manera didáctica en tres enfoques: basados en umbrales, basados en regresión y basados en clasificación.
 - **dlordinal** [55]: utilizada específicamente en el marco de este proyecto para la evaluación asimétrica, aportando implementaciones computacio-



nalmente eficientes de métricas exclusivas como la Sensibilidad Mínima (MS) o el Error Absoluto Medio Promedio (AMAE).

- **Seguimiento de experimentos y paralelización:** dada la inmensa carga computacional de la validación cruzada, se recurre a `joblib` [56] para paralelizar la ejecución de los algoritmos en CPU, así como a `tqdm` [57] para la monitorización de tiempos. Además, el proyecto se apoya en bibliotecas de rastreo de experimentos como `remayn` [58] para registrar automáticamente las hiperconfiguraciones, modelos generados y resultados, asegurando la trazabilidad y reproducibilidad del estudio.
- **Visualización y Análisis de Series Temporales:** para el análisis gráfico y la interpretación de la evolución temporal de los datos, se emplea `Matplotlib` [59] y `seaborn` [60]. Asimismo, para el manejo avanzado de series temporales y su visualización específica, se considera la biblioteca `Aeon` [61], la cual se ha consolidado para el análisis, predicción y clasificación de datos temporales en Python.

4.3. Conjuntos de datos

En esta sección se detallará el proceso de adquisición y las variables utilizadas, aunque antes, es importante contextualizar el origen de los registros. El estudio se centra en las estaciones meteorológicas de los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX). En la Figura 4.1 se ilustra la ubicación geográfica de ambos aeródromos dentro de la comunidad autónoma de Galicia.

Como se adelantaba en el estado de la técnica, al tratar con estos registros aeroportuarios reales nos enfrentaremos directamente al obstáculo de los datos desbalanceados, ya que los eventos críticos de baja visibilidad representan una minoría frente a las condiciones de cielo despejado.

4.3.1. Adquisición de los datos

Como fuente principal de información se han utilizado los informes meteorológicos de aeródromo (METAR) [13]. Estos patrones estandarizados, publicados por las estaciones meteorológicas de los aeropuertos, proporcionan observaciones regulares sobre las condiciones atmosféricas locales. Un reporte METAR típico presenta una estructura codificada que contiene información crítica para la navegación aérea; por ejemplo, el reporte METAR LEBA 070830Z 12002KT CAVOK 26/15 Q1019 indica,




Figura 4.1: Ubicación geográfica de los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX) dentro de la comunidad autónoma de Galicia. (Fuente: [2])

entre otros parámetros, la identificación del aeródromo (LEBA, identificador del aeropuerto de Córdoba), el momento de la observación, las condiciones de viento, la visibilidad (en este caso, CAVOK indicando condiciones óptimas) y variables termodinámicas como la temperatura y el punto de rocío [62].

La obtención de estos datos históricos se ha realizado a través de la plataforma OGIMET [63], la cual permite el acceso a series temporales completas de observaciones meteorológicas globales. Para este trabajo, los registros en bruto han sido suministrados por el grupo de investigación AYRNA [14] y han sido filtrados para asegurar que se cuenta con un registro por hora. Todos los conjuntos de datos abarcan un período comprendido entre enero de 2010 y diciembre de 2023, lo que representa un total de 122,712 registros con información meteorológica en intervalos de una hora.

Para dar una mayor robustez al estudio, la adquisición de datos no se ha limitado a una fuente, sino que se han integrado dos orígenes de datos meteorológicos de naturaleza complementaria para cada uno de los aeropuertos analizados.

1. **Datos de Sensores de Aeródromo (METAR):** representan las mediciones locales reales capturadas directamente por las estaciones meteorológicas instaladas en las pistas de los aeropuertos [13, 63]. Los conjuntos de datos se componen de las siguientes variables atmosféricas y climatológicas que se pueden ver en la Tabla 4.1.

Tabla 4.1: Variables del conjunto de datos METAR

Identificador	Descripción	Unidad de medida
<i>wind_dir</i>	Dirección del viento	Grados ($^{\circ}$)
<i>wind_speed</i>	Velocidad del viento	Metros por segundo (m/s)
<i>temp</i>	Temperatura	Grados Celsius ($^{\circ}\text{C}$)
<i>dewpt</i>	Punto de rocío	Grados Celsius ($^{\circ}\text{C}$)
<i>press</i>	Presión atmosférica	Hectopascal (hPa)
<i>vis</i>	Visibilidad en metros (variable objetivo)	Metros (m)

2. **Datos de Reanálisis Climático (ERA5):** para complementar las observaciones puntuales de los aeropuertos, se han integrado datos provenientes del modelo ERA5, la quinta generación de reanálisis atmosférico del *European Centre for Medium-Range Weather Forecasts* (ECMWF) [64]. Estos conjuntos de datos combinan observaciones con leyes de la física para construir un historial climático continuo y global. Las variables que aporta esta fuente son las siguientes que se pueden ver en la Tabla 4.2.

Tabla 4.2: Variables del conjunto de datos ERA5

Identificador	Descripción	Unidad de medida
<i>msl</i>	Presión al nivel medio del mar	Pascales (Pa)
<i>t2m</i>	Temperatura a 2 metros	Grados Celsius ($^{\circ}\text{C}$)
<i>tp</i>	Precipitación total	Milímetros (mm)
<i>u10</i>	Componente U del viento a 10 metros	Metros por segundo (m/s)
<i>v10</i>	Componente V del viento a 10 metros	Metros por segundo (m/s)

La combinación de ambas fuentes de datos nos proporciona un conjunto de variables de entrada altamente representativo, que nos sirve como punto de partida para poder trabajar en este estudio.

4.3.2. Exploración y análisis de la variable objetivo

Previo a la fase de preprocesamiento, se ha realizado un análisis exploratorio de datos para intentar comprender la distribución intrínseca y los patrones de comportamiento temporal de la visibilidad en ambos aeropuertos. Entender estos patrones



CAPÍTULO 4. METODOLOGÍA DEL TRABAJO

de aparición de eventos de baja visibilidad resulta fundamental para el posterior diseño de los modelos predictivos.

A continuación, veremos las distribuciones temporales de la visibilidad para los aeropuertos de Santiago de Compostela (LEST) y Vigo (LEVX) basadas en los registros locales de sus sensores. Es importante destacar que para este análisis de pautas temporales se emplean los datos continuos de la variable objetivo, permitiendo observar el comportamiento bruto del fenómeno meteorológico de forma previa a su posterior discretización en categorías ordenadas.

- **Estacionalidad anual y mensual:** al analizar la distribución de la visibilidad en su forma continua original (medida en metros) a lo largo de todo el año (Figura 4.2), se aprecia un claro componente estacional en ambos aeropuertos. Se puede apreciar que los eventos de visibilidad reducida tienen una probabilidad de ocurrencia mucho mayor durante los meses de otoño e invierno, en contraste con los meses de verano, donde las condiciones despejadas son claramente dominantes.
- **Comportamiento semanal:** las Figuras 4.3 y 4.4 muestran la fluctuación de la visibilidad a lo largo de los días de la semana. A diferencia de lo que se ha visto en la estacionalidad anual y mensual, los eventos meteorológicos no presentan dependencias estrictas respecto al día de la semana en el que se encuentren. Esto se confirma al observar una distribución relativamente homogénea de lunes a domingo.
- **Ciclo circadiano (Distribución horaria):** el patrón temporal más crítico y evidente para la predicción de visibilidad se encuentra en su distribución horaria. Como se puede ver en la Figura 4.5, las gráficas evidencian una fuerte caída de la visibilidad durante las horas nocturnas y de madrugada, alcanzando su punto crítico justo antes y durante el amanecer. No obstante, al contrastar ambos aeropuertos, se aprecia que en LEVX las condiciones de baja visibilidad e inercia de la niebla tienden a prolongarse durante más tiempo a lo largo de la noche en comparación con LEST, reflejando una mayor persistencia nocturna del fenómeno en el aeropuerto de Vigo. Posteriormente, con la salida del sol y por tanto el aumento de las temperaturas que favorecen la evaporación, la niebla tiende a disiparse y a aparecer con menos frecuencia, recuperando los niveles óptimos de visibilidad a lo largo de las horas centrales del día en ambos casos.

Estas conclusiones conjuntas sacadas del análisis exploratorio confirman la importancia que puede llegar a tener el contexto temporal. Es por ello que las variables



CAPÍTULO 4. METODOLOGÍA DEL TRABAJO

de la fecha y hora se descompondrán durante el preprocesamiento, permitiendo a los algoritmos asimilar estos patrones cíclicos de gran importancia para una correcta clasificación ordinal.




Figura 4.2: Comparativa de la distribución de la visibilidad por mes: LEST (arriba) y LEVX (abajo).




Figura 4.3: Comparativa de la distribución de la visibilidad por día de la semana entre LEST (arriba) y LEVX (abajo).




Figura 4.4: Comparativa de la evolución promedio de la visibilidad durante la semana entre LEST (arriba) y LEVX (abajo).




Figura 4.5: Comparativa de la distribución de la visibilidad por hora del día entre LEST (arriba) y LEVX (abajo).

Por otro lado, además de los patrones temporales analizados, el análisis exploratorio confirma una alta asimetría en la distribución de las categorías de la variable objetivo, enfrentándonos a un problema **altamente desbalanceado**. La variable objetivo de visibilidad ($\mathcal{V}$) ha sido discretizada en cuatro clases estrictamente ordenadas, cuyos rangos definen la severidad de la restricción visual:

- $\mathcal{C}_0 \rightarrow \mathcal{V} < 500$ m
- $\mathcal{C}_1 \rightarrow 500 \text{ m} \leq \mathcal{V} < 1000$ m
- $\mathcal{C}_2 \rightarrow 1000 \text{ m} \leq \mathcal{V} < 5000$ m

- $\mathcal{C}_3 \rightarrow 5000 \text{ m} \leq \mathcal{V} < \infty$

Como se detalla en la Tabla 4.3, las condiciones de visibilidad despejada (clase $\mathcal{C}_3$) dominan de manera abrumadora los conjuntos de datos, representando el 87,36 % en LEST y el 83,70 % en LEVX del total de patrones de la muestra. Por el contrario, los eventos de visibilidad baja ($\mathcal{C}_1$) y extremadamente baja ($\mathcal{C}_0$) representan una minoría casi marginal (apenas un 2,41 % en LEST y un 7,25 % en LEVX de forma conjunta). Sin embargo, son precisamente estos eventos infrecuentes los más críticos a nivel operativo, puesto que son los que obligan a activar los planes y procedimientos de baja visibilidad en los entornos aeroportuarios para mantener la seguridad aérea.

Tabla 4.3: Número total de patrones por clase que ilustran el desequilibrio de datos en LEST y LEVX.

Aeropuerto	Clase	Total de patrones
LEST	$\mathcal{C}_0$	1.793 (1,46 %)
	$\mathcal{C}_1$	1.169 (0,95 %)
	$\mathcal{C}_2$	12.545 (10,22 %)
	$\mathcal{C}_3$	107.204 (87,36 %)
LEVX	$\mathcal{C}_0$	6.359 (5,18 %)
	$\mathcal{C}_1$	2.538 (2,07 %)
	$\mathcal{C}_2$	11.107 (9,05 %)
	$\mathcal{C}_3$	102.707 (83,70 %)

4.3.3. Preprocesamiento e ingeniería de características

El punto de partida de esta fase son los conjuntos de datos proporcionados en bruto descritos en la sección 4.3.1: los datos METAR y los datos ERA5. Sin embargo, con el objetivo de extraer información adicional a esos datos que puedan dar más información y mejorar el rendimiento de los modelos predictivos, se ha llevado a cabo una fase de preprocesamiento e ingeniería de características.

4.3.3.1. Planteamiento como tarea de predicción

Para transformar los datos estáticos en un problema de series temporales enfocado a la predicción futura, se ha utilizado el módulo especializado en Python `skforecast` [49]. Este proceso se encarga automáticamente del alineamiento temporal de los datos, de modo que las variables observadas en el instante actual t se emparejen para predecir la etiqueta de visibilidad correspondiente al instante futuro $t + 1$ (predicción a 1 hora vista).



4.3.3.2. Modelos autorregresivos

La visibilidad atmosférica presenta una fortísima inercia temporal, por lo que se ha explotado esta propiedad mediante la generación de características autorregresivas:

- **Incorporación de *lags* (valores autorregresivos)**: la visibilidad atmosférica presenta una fortísima inercia temporal. Para que los modelos consideren esta información previa, se han incorporado como valores de entrada los valores pasados de la variable objetivo, concretamente los valores de las últimas 6 horas (*lag_1*, *lag_2*, *lag_3*, *lag_4*, *lag_5*, *lag_6*), así como el registro de la hora exacta del día anterior (*lag_24*).
- **Proporciones en ventanas móviles (*Rolling proportions*)**: se ha calculado la proporción de tiempo que la atmósfera ha estado en cada una de las cuatro clases de visibilidad durante las últimas 72 horas mediante ventanas móviles (*roll_proportion_72_class_X*, siendo *X* el número de la clase).

4.3.3.3. Transformaciones de variables externas

También, se han aplicado transformaciones para optimizar la representación de variables físicas:

- **Transformación de variables cíclicas**: la dirección del viento (*wind_dir*) se mide en grados de 0 a 360. Para un modelo matemático, el grado 359 (norte) parece extremadamente distante el grado 1 (norte), cuando en realidad en términos meteorológicos son casi idénticos. Para resolver este problema, se ha aplicado una transformación trigonométrica sobre el ángulo, calculado su seno y su coseno (*wind_sin*, *wind_cos*). De este modo, la naturaleza cíclica del viento queda perfectamente codificada.

4.3.4. Conjuntos de datos para la experimentación

Como resultado de todo este proceso, no se ha generado un único conjunto de datos con todas las variables, sino que se ha realizado una experimentación dividida por módulos con el objetivo de cuantificar el impacto y el poder predictivo de cada fuente de información de manera aislada y combinada, a esto se le llama estudio de ablación. Finalmente, en la experimentación se contará con cuatro conjuntos de datos distintos para cada aeropuerto (8 en total):

1. **Datos solo autorregresivos**: Este conjunto de datos contiene únicamente el historial autorregresivo de la visibilidad, prescindiendo de las variables puramente meteorológicas (temperatura, viento, etc.). Sirve para evaluar si la



inercia temporal de las últimas horas del clima es suficiente para obtener una buena predicción.

2. **Datos de sensores del aeródromo (Solo METAR):** Emplea únicamente las observaciones meteorológicas directas a pie de pista proporcionadas por los informes METAR, detallados también en la sección 4.3.1.
3. **Datos de reanálisis climático (Solo ERA5):** Utiliza exclusivamente las observaciones y variables climáticas procedentes del modelo ERA5, los cuales ya fueron introducidos en la sección 4.3.1.
4. **Conjunto de datos completo (Sensores + autorregresivos + ERA5):** Fusión final de todas las fuentes de información, convirtiéndolo en el conjunto de datos más completo del proyecto. Combina los datos proporcionados por los sensores, las variables autorregresivas y la estabilidad climática de los datos ERA5, proporcionando al modelo la máxima cantidad de información que disponemos.

Esta división de los datos nos permitirá realizar un análisis comparativo exhaustivo en la fase de experimentación, con el objetivo de poder identificar que conjunto de características resulta más crucial para predecir con éxito las situaciones de baja visibilidad. Para facilitar la comprensión de la estructura de cada configuración, la Tabla 4.4 presenta un resumen detallado de las variables de entrada que componen cada uno de los conjuntos de datos evaluados.

Tabla 4.4: Resumen de las variables de entrada según el conjunto de datos evaluado.

Conjunto de datos	Nº Variables	Variables incluidas
Solo autorregresivos	11	7 retardos temporales (<i>lag_1</i> a <i>lag_6</i> , <i>lag_24</i>) + 4 proporciones en ventana móvil de 72h
Solo sensores (METAR)	5	<i>wind_dir</i> , <i>wind_speed</i> , <i>temp</i> , <i>dewpt</i> , <i>press</i>
Solo reanálisis (ERA5)	5	<i>msl</i> , <i>t2m</i> , <i>tp</i> , <i>u10</i> , <i>v10</i>
Conjunto completo	20	4 variables METAR + 2 variables cíclicas del viento + 3 variables del reanálisis ERA5 + 11 variables autorregresivas



4.3.4.1. Análisis de correlación de variables

Para analizar la dependencia lineal con la visibilidad y descartar problemas de colinealidad entre variables, se han extraído las matrices de correlación para todos los conjuntos de datos. A continuación, se presentan las correlaciones cruzadas y las de entrada frente a salida.

1. Conjunto de datos: solo autorregresivos

En las Figuras 4.6, 4.7, 4.8, 4.9 se muestran las matrices para las variables autorregresivas, que capturan el estado anterior de la visibilidad.

Como se esperaba, estas variables presentan la mayor dependencia lineal con la visibilidad actual de todos los conjuntos de datos que se han estudiado. En LEST, la correlación de *lag_1* (visibilidad hace una hora) con la salida es muy alta (0,72), y va decayendo progresivamente en los *lags* posteriores (*lag_2*: 0,58, *lag_3*: 0,46, etc.). En LEVX se observa un comportamiento muy similar.

Por otro lado, la matriz cruzada revela una alta colinealidad entre los propios *lags* consecutivos (por ejemplo, $r = 0,72$ entre *lag_1* y *lag_2* en LEST, y $r = 0,77$ en LEVX), así como una fuerte correlación negativa esperable entre las proporciones móviles (*roll_proportion*), ya que al ser fracciones en una misma ventana de tiempo, el aumento de una clase implica necesariamente la disminución de las demás.




Figura 4.6: Matriz de correlación cruzada (LEST - Solo Autorregresivos).




Figura 4.7: Correlación respecto a la visibilidad (LEST - Solo Autorregresivos).




Figura 4.8: Matriz de correlación cruzada (LEVX - Solo Autorregresivos).




Figura 4.9: Correlación respecto a la visibilidad (LEVX - Solo Autorregresivos).

2. Conjunto de datos: solo sensores (METAR)

En las Figuras 4.10 y 4.11 se muestran las matrices de correlación para las variables METAR del aeropuerto de Santiago (LEST).

Como se observa en la matriz de la derecha, ninguna variable meteorológica presenta de forma aislada una fuerte dependencia lineal con la visibilidad, siendo la temperatura (*temp*, 0,15) y el punto de rocío (*dewpt*, -0,12) las

más relevantes. En cuanto a la matriz cruzada (izquierda), destaca la fuerte colinealidad esperada entre estas dos variables físicas ($r = 0,76$), mientras que el resto de componentes son linealmente independientes.

Este mismo comportamiento se replica en el aeropuerto de Vigo (LEVX), tal y como se comprueba en las Figuras 4.12 y 4.13, donde la temperatura alcanza una correlación de 0.19 con la visibilidad y mantiene una colinealidad de 0,74 con el punto de rocío.

Matriz de Correlación - Solo METAR (LEST)




Figura 4.10: Matriz de correlación cruzada (LEST - Solo METAR).

Correlación de Entrada vs vis (Solo METAR (LEST))




Figura 4.11: Correlación respecto a la visibilidad (LEST - Solo METAR).




Figura 4.12: Matriz de correlación cruzada (LEVX - Solo METAR).

Correlación de Entrada vs vis (Solo METAR (LEVX))




Figura 4.13: Correlación respecto a la visibilidad (LEVX - Solo METAR).

3. Conjunto de datos: solo reanálisis (ERA5)

En las Figuras 4.14 y 4.15 se exponen las matrices de correlación aislando las variables ERA5 para el aeropuerto de Santiago (LEST).

A diferencia de los datos METAR, en los datos ERA5 la variable con mayor relación directa con la visibilidad no es la temperatura, sino la precipitación total (tp , $-0,19$) y las componentes del viento ($u10$ y $v10$, $-0,21$). Esto indica que los episodios de baja visibilidad están más ligados a los frentes lluviosos y a la ausencia de vientos fuertes. En cuanto a la matriz cruzada, no se aprecian

colinealidades fuertes, siendo la máxima de 0,50 entre ambas componentes del viento.

Al analizar el aeropuerto de Vigo (Figuras 4.16 y 4.17), este patrón se hace más evidente. La precipitación total y la componente v del viento alcanzan unas correlaciones de $-0,36$ y $-0,33$ respectivamente con la visibilidad, consolidando lo dicho anteriormente.




Figura 4.14: Matriz de correlación cruzada (LEST - Solo ERA5).

Correlación de Entrada vs vis (Solo ERA5 (LEST))




Figura 4.15: Correlación respecto a la visibilidad (LEST - Solo ERA5).




Figura 4.16: Matriz de correlación cruzada (LEVX - Solo ERA5).

Correlación de Entrada vs vis (Solo ERA5 (LEVX))




Figura 4.17: Correlación respecto a la visibilidad (LEVX - Solo ERA5).

4. Conjunto de datos completo: METAR + ERA5 + autorregresivos

Finalmente, en las Figuras 4.18, 4.19, 4.20 y 4.21 se presentan las matrices correspondientes al conjunto de datos completo, el cual junta todas las fuentes de información descritas anteriormente.

Al observar las correlaciones de las variables de entrada respecto a la salida, se hace evidente la jerarquía de las distintas características en este problema. Las variables autorregresivas presentan la relación lineal más alta con la visibilidad, con *lag_1* superando el coeficiente de 0,70 en ambos aeropuertos. Después, y



CAPÍTULO 4. METODOLOGÍA DEL TRABAJO

a considerable distancia, se sitúan las variables aportadas por ERA5 (como la componente del viento $v10$ o la precipitación tp , que alcanzan correlaciones en torno a $-0,25$ en LEVX), relegando a los parámetros METAR a un impacto casi residual

Por el otro lado, la matriz cruzada de este conjunto completo consolida visualmente los bloques de colinealidad identificados previamente, como la estrecha relación entre temperatura y punto de rocío, o la alta dependencia entre $lags$ consecutivos).




Figura 4.18: Matriz de correlación cruzada (LEST - Conjunto completo).




Figura 4.19: Correlación respecto a la visibilidad (LEST - Conjunto completo).




Figura 4.20: Matriz de correlación cruzada (LEVX - Conjunto completo).




Figura 4.21: Correlación respecto a la visibilidad (LEVX - Conjunto completo).

4.3.5. División de los datos

Una fase importante en el diseño experimental de cualquier sistema de ML es la correcta división del conjunto de datos para las fases de entrenamiento y evaluación. Debido a la naturaleza del problema abordado en este proyecto, los métodos tradicionales de partición aleatoria o validación cruzada estándar (*K-Fold Cross Validation*) resultan inaplicables. El uso de estas técnicas de partición aleatoria destruiría la de-



pendencia temporal de los registros e introduciría un sesgo conocido como fuga de datos, permitiendo a los modelos aprender de eventos futuros para predecir sucesos pasados [65, 66].

Para evitar esto y simular un entorno de despliegue real, se ha dividido en una partición estrictamente cronológica [67]. Bajo esta partición, los conjuntos de datos de ambos aeropuertos se dividen de la siguiente manera:

- **Conjunto de entrenamiento (*Train set*):** Representa el 75 % inicial del conjunto de datos, comprendiendo los registros desde enero de 2010 hasta julio de 2020.
- **Conjunto de evaluación (*Test set*):** Corresponde al 25 % restante del conjunto de datos, comprendiendo desde los registros de julio de 2020 hasta los últimos registros de diciembre de 2023.

Para verificar que esta división cronológica no ha alterado significativamente la representación de los eventos meteorológicos, se ha analizado la distribución de las categorías en ambos subconjuntos. Las Tablas 4.5 y 4.6 muestran el número de patrones y la proporción de cada clase para los conjuntos de entrenamiento y prueba, respectivamente. Como se puede observar, a pesar de realizar una partición temporal estricta y no aleatoria, las proporciones del desbalanceo se mantienen consistentes respecto a la muestra original, garantizando que los modelos sean evaluados bajo unas condiciones representativas de la realidad operativa en ambos aeropuertos.

Tabla 4.5: Distribución de clases en el conjunto de entrenamiento (*Train set*).

Aeropuerto	Clase	Total de patrones
LEST	C_0	1.407 (1,53 %)
	C_1	939 (1,02 %)
	C_2	9.588 (10,42 %)
	C_3	80.099 (87,03 %)
LEVX	C_0	4.506 (4,90 %)
	C_1	1.904 (2,07 %)
	C_2	8.979 (9,76 %)
	C_3	76.644 (83,28 %)

Tabla 4.6: Distribución de clases en el conjunto de evaluación (*Test set*).

Aeropuerto	Clase	Total de patrones
LEST	C_0	386 (1,26 %)
	C_1	230 (0,75 %)
	C_2	2.957 (9,64 %)
	C_3	27.105 (88,35 %)
LEVX	C_0	1.853 (6,04 %)
	C_1	634 (2,07 %)
	C_2	2.128 (6,94 %)
	C_3	26.063 (84,96 %)

4.4. Algoritmos y modelos empleados

En esta sección se detallarán los distintos modelos de ML que son empleados en el proceso de experimentación de este proyecto. Se utilizarán tanto modelos nominales como ordinales para poder realizar una comparación exhaustiva entre ellos. La mayoría de los modelos están implementados a través de las librerías de software `scikit-learn` [50], `mord` [54], `skordinal` [53], `LightGBM` [51]. En la siguiente subsección se detallan los métodos que se han seleccionado.

4.4.1. Modelos nominales de referencia

Para poder comprobar empíricamente el valor aportado por las metodologías ordinales, se han incluido dos algoritmos tradicionales de clasificación nominal. Estos algoritmos funcionan como *baselines*, tratando las distintas clases de visibilidad como categorías independientes sin ninguna relación jerárquica:

1. **Regresión Logística (*Logistic Regressor*)**: este modelo estadístico clásico estima la probabilidad de pertenencia a cada clase mediante funciones logísticas independientes, sirviendo como la línea base del estudio [6]. Su implementación se ha llevado a cabo utilizando la librería `scikit-learn` [50] mediante el algoritmo SAGA (*Stochastic Average Gradient*), el cual es una variante rápida y eficiente diseñada para grandes volúmenes de datos [68]. Para intentar paliar el gran problema del desbalanceo de datos, el modelo se ha configurado con pesos de clase balanceados, penalizando de forma asimétrica los errores en las categorías minoritarias de baja visibilidad.

2. **LightGBM (*Light Gradient Boosting Machine*)**: este algoritmo, implementado a través de su librería oficial [51], representa una evolución eficiente de los modelos de *Gradient Boosting* basados en árboles de decisión. A diferencia de los enfoques tradicionales que construyen los árboles por niveles, este algoritmo emplea una estrategia de crecimiento por hojas, lo que le permite optimizar la función de pérdida de manera más agresiva y modelar relaciones no lineales complejas en los datos meteorológicos [25]. Al igual que en la Regresión Logística, se ha mitigado el sesgo de la clase mayoritaria mediante la ponderación asimétrica de clases.

4.4.2. Modelos de clasificación ordinal

El centro de la experimentación del proyecto se fundamenta en estos algoritmos diseñados expresamente para restringir la predicción al orden natural de las clases. Dentro de este ámbito, se han evaluado modelos lineales, de arquitecturas profundas, y meta-algoritmos de ensamblado:

1. **Regresión Logística *All-Threshold* (LogisticAT)**: este modelo proyecta los principios de la regresión logística tradicional al espacio ordinal. El algoritmo se enmarca dentro de las metodologías basadas en umbrales, asumiendo que, para un problema de clasificación con Q clases, existe un conjunto de $Q + 1$ umbrales ordenados matemáticamente ($\theta_0 \leq \theta_1 \leq \dots \leq \theta_Q$) [2]. Esta restricción divide la recta real unidimensional, sobre la cual se proyectan los patrones de entrada, en Q intervalos distintos. De este modo, la etiqueta asignada a un patrón dependerá del intervalo en el que recaiga su proyección: si se sitúa entre los umbrales θ_{q-1} y θ_q , el patrón pertenecerá a la categoría C_q , teniendo en cuenta por definición que los extremos son $\theta_0 = -\infty$ y $\theta_Q = +\infty$ [2]. A nivel de implementación, este modelo se ha construido sobre la librería **mord** [54], aplicando modificaciones específicas en la función de pérdida y en el cálculo del gradiente para inyectar una matriz de ponderación asimétrica que penaliza severamente los errores de clasificación en las clases minoritarias.
2. **Red Neuronal con Particiones Ordenadas (NNOP, del inglés, *Neural Network with Ordered Partitions*)**: este algoritmo adapta la arquitectura de las redes neuronales artificiales clásicas para abordar específicamente problemas de clasificación ordinal [69]. El modelo utiliza un esquema de codificación basado en particiones ordenadas (*Ordered Partitions*) para las etiquetas. A nivel arquitectónico, la red está compuesta por una capa oculta y una capa de salida que contiene exactamente $Q - 1$ neuronas, donde Q es el número total de clases [1]. La regla de decisión del modelo evalúa estas salidas de forma secuencial: la clase predicha se determina mediante el primer nodo de salida



cuya activación supera un umbral de probabilidad predefinido (típicamente $T = 0,5$) [69]. Para la predicción de la visibilidad, esta estructura resulta muy valiosa, ya que la red aprende las transiciones naturales entre las diferentes categorías meteorológicas, evaluando secuencialmente si las condiciones han superado el umbral crítico para degradarse al siguiente nivel de niebla. A nivel de implementación, el modelo se ha extraído del marco de trabajo proporcionado por la librería `skordinal` [52].

3. **Red Neuronal basada en el Modelo de Probabilidades Proporcionales (NNPOM, del inglés, *Neural Network based on Proportional Odds Model*)**: este algoritmo integra la capacidad de aprendizaje no lineal de las redes neuronales con los fundamentos estadísticos del modelo clásico de probabilidades proporcionales (POM, del inglés, *Proportional Odds Model*) [37]. A diferencia del modelo NNOP, la arquitectura de NNPOM consta de una capa oculta conectada a una capa de salida compuesta por una única neurona. La peculiaridad matemática de este diseño radica en que dicha neurona de salida está equipada con $Q - 1$ umbrales ajustables, donde Q representa el número total de clases ordenadas [70]. El modelo aplica los principios del POM estándar sobre esta neurona para generar salidas probabilísticas, estimando la probabilidad acumulada de que un patrón pertenezca a una categoría específica o a las inferiores [1]. En el contexto de la predicción de baja visibilidad, esto permite estimar de forma rigurosa la probabilidad de que las condiciones meteorológicas se degraden hasta un nivel crítico o peor. La implementación y entrenamiento de este modelo se ha llevado a cabo utilizando el entorno proporcionado por la librería `skordinal` [52].
4. **Descomposición Ordinal mediante Ensamblado (*Ordinal Decomposition*)**: este enfoque algorítmico aborda la clasificación ordinal mediante una estrategia de reducción, transformando el problema original de Q clases en un conjunto de subproblemas de clasificación binaria independientes [1]. A diferencia de los métodos de umbral, este modelo define una matriz de codificación para crear varios clasificadores base (por ejemplo, modelos de regresión logística binaria). Utilizando el esquema estándar de particiones ordenadas (*Ordered Partitions*), el problema se divide en $Q - 1$ submodelos binarios, donde cada uno se entrena para responder a la pregunta de si la etiqueta real es mayor que un nivel k específico [35]. Posteriormente, las predicciones de esta batería de clasificadores se agregan utilizando una regla de decisión estructurada, como el método de estimación de probabilidades de Frank y Hall, para reconstruir la predicción ordinal final [35]. En la operativa meteorológica, esta técnica resulta sumamente intuitiva y robusta: equivale a entrenar “expertos” binarios independientes especializados en detectar si la visibilidad caerá por debajo



CAPÍTULO 4. METODOLOGÍA DEL TRABAJO

de cada umbral operativo del aeropuerto, fusionando luego sus veredictos. La implementación de este algoritmo se ha llevado a cabo mediante el marco de trabajo de la librería **skordinal** [53].

Capítulo 5

Desarrollo y experimentación

El objetivo de este capítulo es establecer el marco experimental sobre el cual se fundamenta el análisis de resultados posterior. Aunque los fundamentos teóricos y las decisiones de diseño se han detallado a lo largo del Capítulo 4, a continuación se presenta un resumen de los elementos que componen el entorno de validación empírica: el diseño del experimento, los conjuntos de datos, los modelos evaluados y las métricas seleccionadas.

Todo el código desarrollado para la preparación de los datos y la ejecución de los experimentos expuestos en este capítulo se encuentra disponible en el siguiente repositorio de GitHub al cual se puede acceder a través del siguiente enlace: <https://github.com/p92canrj/codigoTFG>.

5.1. Diseño del experimento

Se ha diseñado la fase experimental bajo un esquema riguroso de evaluación para garantizar la solidez, reproducibilidad y validez estadística del estudio.

En primer lugar, todas las ejecuciones serán evaluadas siguiendo un esquema de validación cronológica (tal y como se detalló en la Sección 4.3.5). Los modelos se entrenarán con los registros históricos comprendidos entre enero de 2010 y julio de 2020, evaluando su capacidad de generalización exclusivamente sobre datos futuros no vistos, correspondientes al período de julio de 2020 a diciembre de 2023.

En segundo lugar, se aplicará una metodología de ejecuciones múltiples, para así evitar que las conclusiones de este trabajo se puedan ver sesgadas por una inicialización particularmente favorable o desfavorable. Concretamente, se realizarán 30 ejecuciones independientes modificando la semilla aleatoria del entorno de pro-

gramación en cada iteración. De este modo, los resultados que se presentarán en el análisis para cada métrica corresponderán al valor medio obtenido tras realizar estas 30 ejecuciones. Esta práctica garantizará que las diferencias de rendimiento que se observen entre los enfoques nominales y ordinales sean estadísticamente robustas y representativas.

5.2. Conjuntos de datos evaluados

Para cuantificar el valor predictivo que aporta cada fuente de información (sensores locales, inercia autorregresiva y reanálisis climático ERA5) de manera aislada y combinada, se ha llevado a cabo un estudio de ablación. La experimentación se ha ejecutado sobre un total de ocho conjuntos de datos independientes: cuatro pertenecientes al aeropuerto de Santiago de Compostela (LEST) y otros cuatro al aeropuerto de Vigo (LEVX). El detalle exhaustivo sobre la composición y estructura de cada configuración se encuentra en la Sección 4.3.4. A continuación, se resumen los cuatro escenarios evaluados:

1. **Solo autorregresivos:** este conjunto contiene únicamente el historial autorregresivo de la visibilidad, prescindiendo de las variables meteorológicas externas. Su objetivo es evaluar si la inercia temporal de las últimas horas es suficiente para obtener una predicción precisa.
2. **Solo sensores (METAR):** emplea únicamente las observaciones meteorológicas directas a pie de pista proporcionadas por los informes METAR (temperatura, punto de rocío, presión, velocidad y dirección del viento).
3. **Solo reanálisis (ERA5):** utiliza exclusivamente las observaciones y variables climáticas procedentes del modelo de reanálisis ERA5.
4. **Conjunto de datos completo:** fusión de las tres fuentes de información anteriores. Este escenario permite evaluar el modelo bajo las condiciones de máxima disponibilidad de datos.

5.3. Modelos de aprendizaje automático evaluados

Para abordar el problema de clasificación ordinal de la visibilidad, se plantea una comparativa directa entre modelos que ignoran el orden inherente de las clases



(enfoque nominal) y modelos diseñados específicamente para aprovechar esta jerarquía (enfoque ordinal).

Por un lado, como **algoritmos nominales** (que actúan como línea base), se han ejecutado:

- Regresión Logística (*Logistic Regression*).
- *LightGBM Classifier* (modelo basado en *gradient boosting*).

Por otro lado, como **algoritmos ordinales**, se han entrenado las siguientes arquitecturas profundas y de aprendizaje automático:

- *LogisticAT* (*Logistic All-Threshold*).
- Descomposición Ordinal (*Ordinal Decomposition*).
- *NNOP* (*Neural Network with Ordinal Partitions*).
- *NNPOM* (*Neural Network with Proportional Odds Model*).

Todos estos modelos han sido optimizados mediante una búsqueda aleatoria de hiperparámetros (*Randomized Search CV* con 30 iteraciones y validación cruzada de 3 *folds*) en sus respectivas fases de entrenamiento para garantizar una comparación equitativa. Como métrica guía para la selección de la mejor configuración en dicha búsqueda se ha utilizado el **AMAE** (*Average Mean Absolute Error*), ya que penaliza de forma equitativa el error en las clases minoritarias, un factor crítico en datos meteorológicos desbalanceados.



Tabla 5.1: Espacio de búsqueda de hiperparámetros para los modelos evaluados.

Modelo	Hiperparámetro	Valores Explorados
Regresión Logística	C (Regularización)	{0.001, 0.01, 0.1, 1, 10, 100, 1000}
LightGBM	<i>n_estimators</i>	{50, 100, 200}
	<i>max_depth</i>	{10, 20, -1}
	<i>num_leaves</i>	{20, 31, 50}
	<i>learning_rate</i>	{0.1, 0.2, 0.3}
LogisticAT	α (Regularización)	{0.001, 0.01, 0.1, 1, 10, 100, 1000}
Descomp. Ordinal	<i>dtype</i> (Estrategia)	{ <i>ordered_partitions</i> , <i>one_vs_next</i> , <i>one_vs_followers</i> , <i>one_vs_previous</i> }
	<i>decision_method</i> (Pérdida)	{ <i>frank_hall</i> , <i>exponential_loss</i> , <i>hinge_loss</i> , <i>logarithmic_loss</i> }
NNOP / NNPOM	<i>n_hidden</i> (Neuronas)	{10, 50}
	<i>max_iter</i> (Épocas)	{250, 500}
	<i>lambda_value</i> (Reg. L2)	{0.001, 0.01, 0.1, 1}

5.4. Métricas de evaluación

Dado que el problema predictivo no solo cuenta con un orden natural en sus clases, sino que también presenta un severo desbalanceo (donde las situaciones de baja visibilidad son eventos críticos pero minoritarios), la tradicional tasa de acierto (CCR) resulta insuficiente. Para obtener una visión real del rendimiento, los modelos se evalúan a través de las siguientes métricas especializadas:

- **Métricas de rendimiento global:** la Tasa de Acierto (CCR) y la Precisión Balanceada (BA). Esta última calcula el promedio de los aciertos por categoría, ofreciendo una métrica más equitativa.
- **Métricas de error ordinal:** el Error Absoluto Medio Promedio (AMAE) y el Error Absoluto Medio Máximo (MMAE). Ambas métricas penalizan más



severamente a los modelos que cometen errores mayores o que desatienden las clases minoritarias.

- **Métricas de concordancia:** el estadístico *Quadratic Weighted Kappa* (QWK), que mide el grado de acuerdo entre las predicciones y los valores reales penalizando los errores de forma cuadrática según su lejanía en la escala ordinal.
- **Métricas de sensibilidad:** la Sensibilidad Mínima (MS), que evalúa el rendimiento específico sobre la clase con menor tasa de acierto, permitiendo identificar la capacidad del modelo para detectar los eventos meteorológicos más adversos.

Capítulo 6

Resultados y discusión

6.1. Análisis de resultados

En esta sección, se detallan y analizan los resultados empíricos obtenidos por los diferentes modelos predictivos. Tal y como se expuso en la Sección 2.6, el análisis de los resultados se apoyará en una combinación de métricas nominales junto con otras métricas específicamente diseñadas para penalizar el error en problemas ordinales.

Esto nos permitirá identificar qué modelos no solo aciertan más a nivel global, sino cuáles son verdaderamente capaces de detectar las condiciones de baja visibilidad minimizando los errores catastróficos.

6.1.1. Resultados del conjunto de datos completo (Autorregresivos + sensores + ERA5)

El análisis de los resultados obtenidos en la Tabla 6.1 nos da varias conclusiones importantes sobre el comportamiento de cada uno de los modelos frente al problema planteado en este trabajo. En primer lugar, evaluando las métricas nominales estándar, se observa que el modelo LightGBM presenta un desempeño extraordinariamente robusto, logrando las mayores CCR en ambos aeropuertos (87,04 % en LEST y 84,99 % en LEVX). También, este modelo demuestra una gran capacidad de adaptarse a los datos, obteniendo los mejores resultados de la tabla en cuanto a la BA.

Sin embargo, estamos en el terreno de la predicción de la visibilidad en los aeropuertos y el objetivo principal en este ámbito es penalizar los errores catastróficos, es decir, evitar que el modelo confunda un día despejado con una día de niebla densa. Al observar las métricas puramente ordinales (AMAE y MMAE), las virtudes de la



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

metodología ordinal salen a relucir frente a los modelos estocásticos tradicionales.

Si comparamos directamente el modelo base lineal, la Regresión Logística nominal, frente a su variante ordinal (LogisticAT), o frente a redes neuronales ordinales (NNOP y NNPO), resulta evidente la mejora. La Regresión Logística estándar incurre en el mayor MMAE de toda la tabla de resultados, con un 0,9583 en LEST. Esto significa que, al equivocarse en la clase peor predicha, el modelo se desvía prácticamente en una clase entera. Por el contrario, la variante ordinal LogisticAT ya reduce este valor a 0,6691, y la red NNPO logra reducir este error a 0,6315 en LEST, lo que representa una reducción de más del 30 % de errores severos. Este mismo patrón se replica en LEVX, donde el modelo ordinal NNOP logra el mejor resultado en AMAE (0,4544) y en MMAE (0,6294).

Por último, el comportamiento en MS, métrica que refleja la tasa de acierto en la clase más crítica, revela un escenario interesante. Hay que señalar el extraordinario rendimiento del modelo nominal LightGBM en el aeropuerto de LEST, donde logra el mejor valor de MS del estudio (0,4771). Este hecho se justifica por la naturaleza intrínseca del modelo LightGBM, que al ser un meta-algoritmo avanzado de *gradient boosting*, posee mecanismos internos muy potentes para manejar distribuciones desbalanceadas. Sin embargo, a pesar de este hito por parte del modelo nominal, los modelos ordinales demuestran ser alternativas fiables y consistentes para no ignorar estos eventos infrecuentes. Esto queda evidenciado en el aeropuerto de LEVX, donde la red ordinal NNOP sí logra el mejor desempeño en esta métrica (0,4568), superando ampliamente a los enfoques lineales estándar y demostrando la solidez de la metodología ordinal para la detección de la clase minoritaria.

Tabla 6.1: Resultados obtenidos por los diferentes modelos utilizando el conjunto de datos completo (Sensores + Autorregresivos + ERA5).

Caso de Estudio	Clasificador	CCR (↑)	MS (↑)	BA (↑)	QWK (↑)	AMAE (↓)	MMAE (↓)
LEST	Regresión Logística (Nominal)	0,8440	0,2031	0,5710	0,5154	0,5430	0,9583
	LightGBM (Nominal)	0,8704	0,4771	0,6505	0,5844	0,4532	0,6866
	LogisticAT (Ordinal)	0,7964	0,3903	0,5910	0,5471	0,4841	0,6691
	NNOP (Ordinal)	0,8167	0,4041	0,6251	0,5008	0,4469	0,6658
	NNPO (Ordinal)	0,8302	0,4151	0,6288	0,5663	0,4347	0,6315
	Descomposición Ordinal	0,8518	0,3680	0,6355	0,5911	0,4596	0,7212
LEVX	Regresión Logística (Nominal)	0,8444	0,2768	0,6046	0,7444	0,5066	0,7872
	LightGBM (Nominal)	0,8499	0,3902	0,6385	0,7303	0,4765	0,6858
	LogisticAT (Ordinal)	0,7547	0,3560	0,5913	0,7047	0,4962	0,6658
	NNOP (Ordinal)	0,8111	0,4568	0,6249	0,7088	0,4544	0,6294
	NNPO (Ordinal)	0,7939	0,3921	0,6234	0,7216	0,4562	0,6332
	Descomposición Ordinal	0,8250	0,2745	0,6093	0,7351	0,4977	0,7690



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

Si bien la Tabla 6.1 ofrece una visión cuantitativa del rendimiento, el verdadero impacto operativo de la metodología ordinal se aprecia al investigar la distribución espacial de los errores. Para ver este comportamiento, la Figura 6.1 muestra las matrices de confusión medias obtenidas por el mejor modelo nominal (LightGBM) y un modelo ordinal lineal (LogisticAT) en ambos aeropuertos.

Al analizar estas matrices, el concepto de “error catastrófico” cobra un sentido visual directo: clasificaciones erróneas ubicadas en los extremos opuestos de la diagonal principal. En el contexto aeronáutico, el error más peligroso para la seguridad de un vuelo es el falso negativo extremo (es decir, predecir la clase 3: visibilidad despejada, cuando la condición real es la clase 0: visibilidad extremadamente baja).

Observando los resultados para el aeropuerto de Santiago (LEST), el modelo nominal LightGBM incurre en este fallo crítico en un alto 7,46 % de los eventos de visibilidad extremadamente baja. Por el contrario, el modelo ordinal LogisticAT restringe este error a un mínimo 0,31 %. Esta drástica reducción también se puede observar en el aeropuerto de Vigo (LEVX), donde el fallo catastrófico (Clase 0 predicha como 3) desciende del 5,71 % en el enfoque nominal al 0,96 % en el ordinal.

Otro error peligroso en el contexto aeronáutico es la falsa alarma extrema, es decir, predecir una visibilidad extremadamente baja cuando el cielo está completamente despejado, ya que esto puede provocar unos gastos elevados innecesarios a la hora de desviar vuelos o activar un plan de prevención. En este caso, los modelos ordinales también protegen frente a este tipo de error reduciendo del 0,28 % al 0,14 % en LEST, y del 1,09 % al 0,69 % en LEVX.

Estas matrices confirman de forma contundente la hipótesis topológica de la clasificación ordinal: al integrar el orden natural de las etiquetas en la función de coste del algoritmo, las predicciones erróneas tienden a concentrarse en las clases adyacentes a la diagonal principal, evitando así desviaciones más graves que pondrían en riesgo la operatividad aeroportuaria.




Figura 6.1: Comparativa de matrices de confusión entre enfoques nominales y ordinales para el conjunto de datos completo.

6.1.2. Estudio del impacto de las fuentes de datos

Una vez analizado el rendimiento máximo alcanzable utilizando la totalidad de la información extraída, resulta necesario evaluar el aporte predictivo individual de cada bloque de características. En el ámbito del aprendizaje automático, este proceso se conoce formalmente como estudio de ablación [71].

El objetivo en este apartado es cuantificar el impacto real que tienen sobre los modelos predictivos las tres fuentes de información tratadas: las observaciones meteorológicas locales a pie de pista (sensores METAR del aeropuerto), el contexto



macro-climático proporcionado por modelos físicos (datos ERA5), y la inercia temporal de la visibilidad (datos autorregresivos).

A continuación, se presentan los resultados obtenidos al restringir la información de entrada a cada uno de estos bloques por separado, manteniendo las 30 ejecuciones independientes por modelo para asegurar la robustez de la comparativa.

6.1.2.1. Rendimiento usando solo datos autorregresivos

En esta primera fase del estudio de ablación, se evalúa la capacidad de los modelos para predecir la visibilidad utilizando exclusivamente la inercia temporal de la visibilidad del aeropuerto. Es decir, los algoritmos se alimentan únicamente de los registros de visibilidad de las últimas seis horas y el comportamiento del día anterior, sin ningún conocimiento sobre variables atmosféricas y climatológicas actuales como la temperatura, la presión o el viento. Los resultados de este caso se recogen en la Tabla 6.2.

El análisis de esta tabla revela un peligro en la meteorología. A primera vista, los CCR son extremadamente altos, superando incluso en algunos casos al conjunto de datos completo (por ejemplo, LogisticAT alcanza un 88,65 % en LEST y un 87,7 % en LEVX). Sin embargo, este alto CCR es un espejismo causado por la altísima inercia de la visibilidad y el desbalanceo severo de clases que se presenta. Si un modelo aprende a predecir simplemente que “en la próxima hora hará el mismo tiempo que en la actual”, acertará la gran mayoría de veces porque las horas despejadas predominan con claridad.

La realidad del rendimiento predictivo en este caso se destapa al observar las métricas sensibles a las clases minoritarias. Al carecer de variables atmosféricas y climatológicas, los modelos se vuelven virtualmente ciegos ante los cambios de estado (por ejemplo, un descenso brusco de temperatura que indique una inminente formación de niebla). Como resultado, la MS cae drásticamente en todos los algoritmos en comparación con el conjunto de datos completo. El modelo ordinal LogisticAT cae hasta 0,1787 en LEST, lo que indica la gran dificultad que tiene de predecir correctamente la clase más infrecuente.

En cuanto a los errores catastróficos, la métrica MMAE sufre un deterioro generalizado. El enfoque nominal lineal (Regresión Logística) dispara su error máximo medio a 1,1335 en LEST, un fallo muy grave. En este entorno, los modelos ordinales vuelven a ofrecer una mejor versión respecto a los nominales: la red neuronal NN-POM logra amortiguar el impacto del error manteniendo el MMAE más bajo de la



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

tabla tanto para LEST (0,7965) como para LEVX (0,7552), pero siendo lógicamente peores resultados que los obtenidos con el conjunto de datos completo.

Tabla 6.2: Resultados obtenidos por los diferentes modelos utilizando solo datos autorregresivos.

Caso de Estudio	Clasificador	CCR ($\uparrow$)	MS ($\uparrow$)	BA ($\uparrow$)	QWK ($\uparrow$)	AMAE ($\downarrow$)	MMAE ($\downarrow$)
LEST	Regresión Logística (Nominal)	0,8503	0,1182	0,5117	0,5030	0,6555	1,1335
	LightGBM (Nominal)	0,8857	0,3711	0,6143	0,6162	0,5398	0,8564
	LogisticAT (Ordinal)	0,8865	0,1787	0,5381	0,6153	0,6131	0,8592
	NNOP (Ordinal)	0,8510	0,3610	0,5876	0,5745	0,5548	0,9396
	NNPOM (Ordinal)	0,8403	0,3543	0,5810	0,5515	0,5496	0,7965
	Descomposición Ordinal	0,8512	0,3011	0,5862	0,5713	0,5640	0,8773
LEVX	Regresión Logística (Nominal)	0,8595	0,1989	0,5376	0,7154	0,6303	0,9824
	LightGBM (Nominal)	0,8682	0,3358	0,5997	0,7211	0,5591	0,8197
	LogisticAT (Ordinal)	0,8770	0,2900	0,5563	0,7371	0,6088	0,8668
	NNOP (Ordinal)	0,8227	0,3602	0,5819	0,6989	0,5553	0,7870
	NNPOM (Ordinal)	0,7862	0,3597	0,5754	0,6817	0,5546	0,7552
	Descomposición Ordinal	0,8651	0,2337	0,5615	0,7279	0,6060	0,9375

Como se realizó en el análisis del conjunto completo de datos, se visualizan la distribución de los errores mediante matrices de confusión. En este caso, al enfrentarnos a un escenario de clasificación más complejo por la reducción de variables, los modelos lineales pierden cierta capacidad para capturar relaciones complejas. Por ello, la Figura 6.2 compara el mejor modelo nominal (LightGBM) frente al modelo ordinal que mejores resultados ha obtenido (NNPOM). En ella se observa cómo se distribuyen los errores ante la carencia de variables meteorológicas locales y de ERA5. En este caso, el “espejismo” provocado por la inercia temporal se refleja de forma evidente en los errores de clase 3 a 0 (predecir cielo totalmente despejado cuando en realidad la visibilidad es nula). Al basarse fuertemente en los registros de las horas anteriores, a los algoritmos les resulta muy difícil cometer un fallo tan brusco en esta dirección, manteniendo este error en un anecdótico 0,24 % para LEST y en torno a un 1 % en LEVX.

Sin embargo, el error inverso (predecir niebla extrema cuando en realidad el cielo está despejado, clase 0 a 3) sí supone un desafío mayor, ya que al carecer de variables climáticas como la temperatura o la presión, los modelos son incapaces de anticipar la disipación rápida de un banco de niebla. En este escenario, el enfoque nominal de LightGBM incurre en este fallo un 13,14 % de las veces en LEST y un 9,92 % en LEVX. Frente a esto, la red ordinal NNPOM vuelve a demostrar su robustez, logrando amortiguar estos errores al 10,54 % en LEST y reduciéndolos casi a la mitad en LEVX (5,94 %).

CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

Esto refuerza la conclusión principal: aunque la inercia temporal infle artificialmente el CCR, cuando se trata de minimizar los errores severos de salto de clase en ausencia de datos atmosféricos, los modelos ordinales profundos continúan ofreciendo un comportamiento significativamente más seguro.




Figura 6.2: Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos autorregresivos.

6.1.2.2. Rendimiento usando solo datos de sensores (METAR)

En el segundo caso de este estudio, se ha evaluado el rendimiento de los modelos restringiendo el conjunto de datos de entrada únicamente a las observaciones registradas por los sensores locales de los aeropuertos (METAR). Los resultados recogidos en la Tabla 6.3 evidencian, como se esperaba, una reducción global en el



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

rendimiento predictivo al prescindir de las otras fuentes complementarias.

Al examinar las métricas de acierto nominal, el modelo LightGBM vuelve a colocarse como el algoritmo más preciso, obteniendo el mayor CCR en ambos aeropuertos (86,79 % en LEST y 85,88 % en LEVX) y el mejor estadístico QWK. De igual forma, en el aeropuerto de LEST logra conservar la mayor MS (0,4301).

Sin embargo, al igual que ocurría con el conjunto de datos completo, las métricas basadas en distancia revelan el verdadero comportamiento de los modelos frente a las falsas alarmas y los falsos negativos extremos. Los algoritmos nominales muestran una fragilidad en este aspecto; la Regresión Logística nominal, por ejemplo, aumenta su MMAE por encima de 1.0 (1,0772 en LEST), lo que indica desviaciones inasumibles en la operatividad aérea.

Ante este escenario de escasez de información, los modelos ordinales profundos confirman su robustez en estas situaciones. En el aeropuerto de Santiago (LEST), la red NNPOM minimiza los errores, liderando el AMAE (0,4649) y el MMAE (0,7146). Esta fortaleza ordinal se replica de manera análoga en Vigo (LEVX), donde NNPOM alcanza el mejor desempeño en AMAE (0,4922) y el modelo NNOP destaca de nuevo por lograr el menor MMAE (0,6944) a la vez que lidera la tasa de acierto en la clase más crítica con un MS de 0,4459.

Tabla 6.3: Resultados obtenidos por los diferentes modelos utilizando únicamente los datos de sensores meteorológicos (METAR).

Caso de Estudio	Clasificador	CCR (↑)	MS (↑)	BA (↑)	QWK (↑)	AMAE (↓)	MMAE (↓)
LEST	Regresión Logística (Nominal)	0,8334	0,1343	0,5414	0,5216	0,5875	1,0772
	LightGBM (Nominal)	0,8679	0,4301	0,6339	0,6445	0,4842	0,7775
	LogisticAT (Ordinal)	0,8372	0,2783	0,5696	0,6162	0,5263	0,8000
	NNOP (Ordinal)	0,8340	0,3996	0,6119	0,6040	0,4756	0,7354
	NNPOM (Ordinal)	0,8143	0,3230	0,6104	0,5945	0,4649	0,7146
	Descomposición Ordinal	0,8601	0,2565	0,5974	0,6283	0,5198	0,8652
LEVX	Regresión Logística (Nominal)	0,8529	0,3076	0,5660	0,7391	0,5736	0,8154
	LightGBM (Nominal)	0,8588	0,3519	0,6114	0,7542	0,5247	0,7684
	LogisticAT (Ordinal)	0,8251	0,2571	0,5482	0,7327	0,5776	0,8297
	NNOP (Ordinal)	0,8225	0,4459	0,6101	0,7370	0,4939	0,6944
	NNPOM (Ordinal)	0,8130	0,3523	0,6134	0,7380	0,4922	0,7010
	Descomposición Ordinal	0,8366	0,3407	0,5635	0,7313	0,5639	0,7524

Como se esta realizando con todos los casos, se muestra la distribución de los errores mediante matrices de confusión comparando LightGBM y NNPOM (Figura 6.3).



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

En el aeropuerto de Santiago (LEST), el modelo nominal LightGBM comete el temido error catastrófico (predecir visibilidad despejada cuando la condición real es de visibilidad extremadamente baja) en un preocupante 7,50 % de los casos de la clase 0. Sin embargo, el modelo ordinal NNPOM consigue reducir este fallo reduciéndolo a un 3,50 %, lo que supone menos de la mitad de errores críticos. Este patrón de protección se repite de forma casi idéntica en el aeropuerto de Vigo (LEVX), donde LightGBM incurre en un 6,94 % de estos casos, frente al 3,08 % logrado por NNPOM.

Respecto a las falsas alarmas graves (predecir visibilidad extremadamente baja cuando el cielo está despejado), ambos modelos logran mantener tasas ínfimas que no suponen un impacto operativo grave. En LEST, estas cifras se sitúan en el 0,15 % para LightGBM y 0,21 % para NNPOM, y en LEVX rondan el 0,75 % y 0,89 %, respectivamente.

Estas matrices nos indican que, ante la reducción de variables, los modelos nominales tienden a dispersar más sus fallos hacia los extremos de la diagonal al no encontrar patrones claros. Por el contrario, las redes neuronales ordinales logran extraer características útiles y, forzadas por su función de coste, juntan la incertidumbre en las clases adyacentes a la diagonal principal, garantizando un comportamiento mucho más seguro en la toma de decisiones aeroportuarias.




Figura 6.3: Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos de sensores (METAR).

6.1.2.3. Rendimiento con reanálisis climático (Solo ERA5)

El último caso de este estudio de ablación intenta predecir la visibilidad de los aeropuertos proporcionando exclusivamente a los modelos los datos ERA5. En este caso, los modelos carecen tanto de la inercia temporal (autorregresivos) como de las mediciones locales a pie de pista (sensores METAR), basándose únicamente en el contexto proporcionado por los datos ERA5. Los resultados de este caso se recogen en la Tabla 6.4.

El análisis de esta tabla nos muestra una caída en la capacidad predictiva de todos los modelos. Al prescindir de los sensores a pie de pista y de la información



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

reciente, los modelos son incapaces de inferir las complejas dinámicas locales que conllevan los cambios de la visibilidad.

Las métricas nominales estándar, como el CCR, caen desplomadas a valores en torno al 45-60 %, lo que supone un comportamiento apenas superior a una predicción aleatoria o mayoritariamente ciega. Otro detalle, es que el índice QWK se hunde hasta valores muy bajos como 0,02 con el modelo de Descomposición Ordinal en LEST, y 0,03 con el modelo de Regresión Logística también en LEST. Esto indica que, basándose únicamente en ERA5, la fiabilidad de las predicciones a la hora de ordenar la gravedad de la visibilidad desaparece casi por completo.

La degradación predictiva se traslada también a la métrica de MS, la capacidad para alertar de las clases más infrecuentes disminuye considerablemente. En el aeropuerto de Santiago (LEST) los enfoques nominales alcanzan su cota más baja (0,0826 en Regresión Logística), mientras que las redes neuronales ordinales (NNOP y NNPO) consiguen resistir ligeramente manteniendo valores superiores al 0,31. En Vigo (LEVX), no consiguen resistir igual bajando a valores en torno al 0,15–0,20.

En relación al MMAE, la regresión nominal arroja errores superiores a 1,32 niveles enteros de visibilidad y la Descomposición Ordinal superiores a 1,81, todo esto en LEST. Mientras que en LEVX, todos los modelos rondan el 1 en esta métrica. Esto implica que los modelos fallan gravemente prediciendo cielos despejados cuando la niebla es extrema, y viceversa. Una vez más, la red NNPO es el único modelo capaz de mantener el MMAE en torno a 0,76 en LEST y 0,96 en LEVX pese a la extrema pobreza de los datos de este conjunto.

En conclusión, este estudio de ablación certifica que el reanálisis ERA5 no es viable tratarlo como conjunto de datos independiente para la predicción de visibilidad. Su función es estrictamente complementaria. Tal y como se evidenció en la evaluación del conjunto de datos completo (Sección 6.1.1), mejora sutilmente la robustez de los modelos siempre que se apoye en las mediciones locales (METAR) y en la inercia temporal (autorregresivos).



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

Tabla 6.4: Resultados obtenidos por los diferentes modelos utilizando únicamente datos de reanálisis climático (ERA5).

Caso de Estudio	Clasificador	CCR ($\uparrow$)	MS ($\uparrow$)	BA ($\uparrow$)	QWK ($\uparrow$)	AMAE ($\downarrow$)	MMAE ($\downarrow$)
LEST	Regresión Logística (Nominal)	0,4842	0,0826	0,4246	0,0322	1,0420	1,3261
	LightGBM (Nominal)	0,5880	0,2516	0,5236	0,1426	0,6831	0,8448
	LogisticAT (Ordinal)	0,5016	0,1348	0,3113	0,0304	1,1620	1,2979
	NNOP (Ordinal)	0,4776	0,3780	0,4968	0,1355	0,6323	0,8409
	NNPOM (Ordinal)	0,5332	0,3159	0,4841	0,1419	0,6812	0,7627
	Descomposición Ordinal	0,4688	0,0933	0,3772	0,0228	1,0563	1,8109
LEVX	Regresión Logística (Nominal)	0,6216	0,1703	0,3936	0,1851	1,0232	1,3694
	LightGBM (Nominal)	0,6613	0,2615	0,4487	0,3237	0,8346	1,0269
	LogisticAT (Ordinal)	0,5536	0,1805	0,3477	0,1882	1,0836	1,2461
	NNOP (Ordinal)	0,4420	0,1575	0,3933	0,2485	0,7715	1,0607
	NNPOM (Ordinal)	0,5155	0,1965	0,3986	0,2916	0,8723	0,9650
	Descomposición Ordinal	0,6057	0,1420	0,4006	0,1748	1,0105	1,2979

Al igual que en los casos anteriores, el análisis de las matrices de confusión (Figura 6.4) resulta interesante para entender cómo se comportan los algoritmos ante la disposición de tener solo los datos ERA5. En esta comparativa entre LightGBM (el mejor modelo nominal) y NNPOM (el modelo ordinal más robusto), se hace evidente la debilidad del enfoque nominal ante conjuntos de datos poco informativos.

En el aeropuerto de Santiago (LEST), LightGBM predice cielos despejados cuando en realidad la visibilidad es nula en un 12,09 % de las ocasiones, y comete el error inverso en un 8,34 %. NNPOM, haciendo valer su naturaleza ordinal, logra amortiguar estos fallos reduciéndolos al 8,29 % y al 2,46 %, respectivamente.

Esta tendencia se hace todavía más notable en Vigo (LEVX). En este aeropuerto, LightGBM alcanza una tasa del 17,50 % prediciendo niebla extrema cuando el cielo está totalmente despejado. Frente a este mal resultado operativo, la red NNPOM demuestra una resistencia notable, rebajando este error a casi una tercera parte (5,76 %).

Estos resultados visuales corroboran lo observado en los resultados con la métrica MMAE: cuando a los algoritmos nominales se les priva de las variables de los sensores locales, sus predicciones se vuelven mucho más erráticas y los fallos se disparan hacia los extremos de las clases. Los modelos ordinales profundos, pese a sufrir también la degradación del acierto global, consiguen confinar sus fallos en torno a la diagonal principal, mitigando en gran medida los errores más penalizados en el ámbito aeronáutico.

CAPÍTULO 6. RESULTADOS Y DISCUSIÓN




Figura 6.4: Comparativa de matrices de confusión entre el mejor modelo nominal y el mejor modelo ordinal utilizando únicamente datos de reanálisis climático (ERA5).

6.2. Discusión de resultados

Tras analizar detalladamente el rendimiento cuantitativo de los modelos a lo largo de los distintos escenarios del estudio de ablación, esta sección tiene como objetivo proporcionar una síntesis global y visual de los resultados empíricos obtenidos. Para ello, el análisis se alejará de las métricas nominales estándar (como el CCR o BA), que han demostrado ser poco representativas y engañosas debido al gran desbalanceo de los datos, para centrarse exclusivamente en evaluar la capacidad de los algoritmos de minimizar los errores más graves en el ámbito aeroportuario y detectar de la forma más fiable las condiciones de visibilidad reducida.

Con este propósito, la discusión se estructurará apoyándose en gráficas que permitirán evaluar el despliegue de un sistema predictivo en este ámbito: en primer lugar, la capacidad de generalización y el compromiso entre acierto y seguridad ante distintas fuentes de información. Y en segundo lugar, la fiabilidad estocástica de sus predicciones frente a variaciones en la inicialización aleatoria de los algoritmos (evaluando la dispersión de los resultados a lo largo de las 30 ejecuciones de un conjunto de datos). Para ello se emplearán diagramas de cajas y de dispersión.

6.2.1. Rendimiento global entre distintos escenarios

Para analizar el comportamiento general de los algoritmos ante distintos niveles de información, en esta sección se ilustra la distribución del rendimiento medio de cada clasificador a lo largo de los ocho conjuntos de datos estudiados en la experimentación. Para la construcción de estos diagramas de caja, cada caja resume la variabilidad de los resultados utilizando ocho valores, donde cada uno representa la media de las 30 ejecuciones independientes realizadas para cada conjunto de datos específico. Esta visión permite identificar qué modelos mantienen un desempeño robusto de forma sistemática y cuáles sufren una mayor degradación al retirar variables de entrada del conjunto de datos.

Para este análisis se han seleccionado las tres métricas que mejor funcionan en este tipo de problemas: la MS, que refleja la capacidad de alertar sobre eventos críticos; y el AMAE junto con el MMAE, que evalúan la gravedad de los errores cometidos.

Observando este gráfico de MS (Figura 6.5), se puede apreciar como los modelos LightGBM, NNOP y NNPOM tienen sus cajas de distribución en la franja superior de la gráfica. Resulta destacable que las redes ordinales (NNOP y NNPOM) presentan cajas mucho más compactas que LightGBM, lo que indica una mayor consistencia de rendimiento a través de los distintos conjuntos de datos, llegando NNOP a alcanzar la mediana más alta del estudio. No obstante, ambas redes presentan un punto atípico inferior, que pertenecen al conjunto de datos ERA5 del aeropuerto de Vigo (LEVX), donde con la pérdida de la demás información sufrió mucho en su rendimiento. Por su parte, LightGBM presenta una mayor dispersión general, pero no muestra colapsos puntuales. En cualquier caso, los tres modelos evitan los resultados malos que afecta a métodos lineales como la Regresión Logística nominal.




Figura 6.5: Comparativa global de la distribución de la MS a través de todos los conjuntos de datos estudiados.

Sin embargo, el verdadero rendimiento del método ordinal aflora cuando se evalúa la gravedad de los fallos.




Figura 6.6: Comparativa global de la distribución del AMAE a través de todos los conjuntos de datos estudiados.




Figura 6.7: Comparativa global de la distribución del MMAE a través de todos los conjuntos de datos estudiados.

En cuanto al AMAE (Figura 6.6), se puede ver una división. Las redes neuronales ordinales (NNOP y NNPOM) y el modelo LightGBM logran las medianas más bajas y mantienen sus distribuciones más compactas en la zona inferior de la gráfica. Por el otro lado, los modelos lineales (Regresión Logística y LogisticAT) y la Descomposición Ordinal sufren una pérdida de rendimiento en algunos casos, evidenciada por la aparición de dos valores atípicos pertenecientes a los conjuntos de datos de ERA5.

La superioridad ordinal la podemos demostrar en la Figura 6.7, que evalúa el MMAE. En esta gráfica, la red ordinal NNPOM se muestra como el modelo más seguro en general para evaluar los conjuntos de datos de este estudio. Su caja de distribución es la más baja y la más compacta de todos los modelos estudiados. En cambio, LightGBM presenta unos valores un poco superiores, y el otro modelo ordinal NNOP muestra una mayor dispersión, con su bigote superior llegando por encima de 1.

6.2.2. Comparativa entre enfoques: nominal vs ordinal

Una vez visto el rendimiento global por métrica en todos los conjuntos de datos, el siguiente paso es enfrentar a los dos algoritmos que, tanto en ese análisis visual como en la evaluación de las tablas de resultados (Sección 6.1), han despuntado como los mejores representantes de sus respectivos enfoques. Por lo tanto, se realizará una comparación directa entre LightGBM, como el mejor enfoque nominal, y la red

CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

neuronal NNPOM, como el mejor enfoque ordinal.

Para realizar esta comparativa se emplean diagramas de dispersión (*scatter plots*) pareados evaluando las métricas MS, AMAE y MMAE. En esta representación, cada punto del gráfico contiene el valor de la métrica que han obtenido ambos modelos sobre un mismo conjunto de datos. La línea diagonal sólida divide el plano y marca el umbral de rendimiento equivalente; los ejes se han dispuesto de manera que, en todas las gráficas de esta sección, los puntos ubicados por encima de la diagonal principal indicarán siempre un mejor desempeño (una victoria) para la red ordinal NNPOM, mientras que los puntos situados por debajo señalarán que ha ganado el modelo nominal LightGBM.




Figura 6.8: Comparativa directa de la MS entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos del estudio.

Comenzando por la capacidad de detección de la clase más infrecuente (Figura 6.8), el gráfico revela un empate técnico en cuanto a número de victorias: de los



CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

ocho escenarios, la red NNPOm logra un mejor desempeño en la mitad de ellos, mientras que LightGBM vence en los otros cuatro. Sin embargo, se observa que en aquellos conjuntos de datos donde LightGBM es superior, logra una mayor distancia vertical respecto a la línea de empate, lo que le otorga una media global ligeramente superior. Este comportamiento confirma que, en términos de MS, el potente modelo de *gradient boosting* nominal es capaz de obtener resultados competitivos.

No obstante, como se ha argumentado a lo largo de este trabajo, el verdadero valor del enfoque ordinal no reside únicamente en la detección bruta, sino en la mitigación del riesgo operativo y la gravedad del error cometido.

Al observar el gráfico (Figura 6.9), la superioridad de la metodología ordinal para mitigar el error se hace evidente de forma visual. De los ocho conjuntos de datos evaluados, en seis de ellos los puntos recaen en el área superior izquierda, situándose por encima de la diagonal principal. Esto demuestra que, en igualdad de condiciones, el modelo ordinal NNPOm comete un error AMAE menor que LightGBM en el 75 % de los casos estudiados.

Sin embargo, como se puede observar en la gráfica, todos los puntos se sitúan relativamente cerca de la línea diagonal. Esta proximidad indica que, aunque la victoria de NNPOm es sistemática, el margen de diferencia en el AMAE entre ambos modelos es ajustado. Este comportamiento estadístico es esperable: dado que el AMAE promedia el error de todas las clases y existe una abrumadora mayoría de situaciones de cielo despejado (clase 3) que ambos modelos aciertan con facilidad, los fallos cometidos en las clases menos frecuentes de niebla quedan diluidos en la media global.




Figura 6.9: Comparativa directa del AMAE entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos del estudio.

Esta ventaja ordinal se acentúa y se vuelve definitiva al analizar el MMAE en la Figura 6.10.

En esta gráfica, los resultados son contundentes: la totalidad de los casos se ubican por encima de la diagonal principal, lo que implica un 100 % de victorias para el enfoque ordinal. Además, a diferencia de lo que ocurría con el AMAE, en este caso sí se aprecia una distancia considerable respecto a la línea de empate en la gran mayoría de los escenarios. Esta separación indica que el modelo nominal LightGBM, a pesar de su gran capacidad global para clasificar, es intrínsecamente mucho más propenso a cometer desviaciones extremas en las peores condiciones.

Este comportamiento generalizado certifica de forma empírica y rotunda la hipótesis central de este trabajo: si bien un modelo nominal avanzado puede llegar a competir o liderar la tasa de acierto (CCR), cuando el objetivo es garantizar la seguridad

reduciendo el coste operativo de los fallos, la integración del orden natural en la red neuronal (NNPOM) se confirma como una estrategia superior en cualquier escenario de disponibilidad de datos meteorológicos.




Figura 6.10: Comparativa directa del MMAE entre la red ordinal NNPOM y el modelo nominal LightGBM en los ocho casos de estudio.

6.2.3. Estabilidad y fiabilidad ante la inicialización aleatoria


Para garantizar la validez estadística y la robustez de los modelos predictivos basados en redes neuronales, resulta metodológicamente necesario evaluar su rendimiento a través de múltiples ejecuciones utilizando distintas semillas de inicialización aleatoria [72]. Especialmente en aplicaciones críticas como el control del tráfico aéreo, caracterizar esta dispersión es fundamental para asegurar que el modelo opera dentro de unos márgenes de seguridad predecibles, independientemente de su estado inicial. Para someter a los algoritmos a esta evaluación, se han aislado los conjuntos de datos con mayor volumen de información y mejores resultados (Conjuntos




CAPÍTULO 6. RESULTADOS Y DISCUSIÓN

Completo de LEST y LEVX) y se ha analizado la dispersión resultante de 30 ejecuciones independientes para las tres métricas fundamentales: MS, AMAE y MMAE.

Las Figuras 6.11 y 6.12 ilustran la variabilidad intrínseca de los modelos ante distintas semillas iniciales a través de diagramas de caja agrupados por métrica y aeropuerto.




(a) MS - LEST




(b) AMAE - LEST

Figura 6.11: Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEST (Parte I).




(c) MMAE - LEST

Figura 6.11: Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEST (Parte II).




(a) MS - LEVX

Figura 6.12: Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEVX (Parte I).



(b) AMAE - LEVX



(c) MMAE - LEVX

Figura 6.12: Distribución del rendimiento a lo largo de 30 inicializaciones aleatorias para el aeropuerto de LEVX (Parte II).

En este contexto aislado, se puede apreciar de forma evidente la diferencia estructural entre los meta-algoritmos basados en árboles y las redes neuronales en ambos aeropuertos. LightGBM, al no depender de una inicialización aleatoria de



pesos tan sensible, se presenta como un bloque casi inamovible en la que sus cajas no presentan dispersión en todas las métricas. Por su parte, las redes neuronales (NNOP y NNPOM), debido a la naturaleza estocástica de su entrenamiento, presentan una dispersión natural más acusada. En la métrica de MS, LightGBM logra sostener una detección superior y más estable. Sin embargo, al observar las gráficas de error (AMAE y MMAE), la red NNPOM logra mantener sus ejecuciones en niveles superiores a los de LightGBM, a pesar de su mayor dispersión de entrenamiento.

Para evaluar el desempeño de ambos modelos de forma más directa, resulta útil realizar un análisis comparativo ejecución por ejecución. La Figura 6.13 expone un análisis cara a cara de las 30 ejecuciones, enfrentando los resultados de LightGBM frente a los de NNPOM para ambos aeropuertos. De esta manera, se puede observar gráficamente qué modelo rinde mejor cuando se evalúan bajo las mismas condiciones de partida.

Este conjunto final de gráficos de dispersión nos muestra cosas reveladoras y resume a la perfección el paradigma abordado a lo largo del trabajo. En el primer par de gráficos (MS), se observa que LightGBM es un modelo excelente, logrando la victoria en la práctica totalidad de las semillas frente a NNPOM en ambos aeropuertos.

Sin embargo, esta aparente superioridad se encuentra en entredicho al evaluar la gravedad de sus fallos. Al observar los gráficos de error (AMAE y MMAE), la gran mayoría de las ejecuciones conjuntas se posicionan a favor de NNPOM. De hecho, en las dos métricas, el método NNPOM no cede prácticamente ninguna derrota ante el modelo nominal en las 60 ejecuciones evaluadas (30 por aeropuerto).

Esta demuestra de nuevo la validez del enfoque ordinal frente a los métodos nominales. Aunque algoritmos como LightGBM logren exprimir el acierto bruto en la detección al máximo, lo hacen a costa de perder el control sobre la gravedad de los errores cometidos. La arquitectura de NNPOM impone una regularización natural que sacrifica una porción del acierto puro a cambio de garantizar una contención drástica y persistente de los errores catastróficos. En un entorno de seguridad y operatividad crítica como es el aeronáutico, este es el comportamiento más indicado.




Figura 6.13: Comparativa pareada de 30 inicializaciones independientes entre NNPOM y LightGBM. (Continúa en la página siguiente)




Figura 6.13: Comparativa pareada de 30 inicializaciones independientes entre NNPOm y LightGBM. (Continuación)

6.3. Test estadísticos

Para asegurar que las conclusiones obtenidas hasta ahora son totalmente fiables, en este apartado se realizan diferentes pruebas estadísticas. Al haber evaluado los modelos en distintos casos y haberlos entrenado múltiples veces con variaciones aleatorias (las 30 semillas), es necesario confirmar de forma matemática que las mejoras de un modelo frente a otro son reales, y no fruto de la casualidad o de una inicialización con suerte.

Para llevar a cabo esta validación, el análisis se apoya en dos herramientas estadísticas y visuales complementarias:

- **Diagramas de Diferencia Crítica (CDD, del inglés *Critical Difference Diagrams*):** esta representación visualiza el ranking global de todos los modelos ordenándolos de mejor a peor. Mediante una línea horizontal continua, el gráfico agrupa y conecta aquellos algoritmos entre los que no existe una diferencia matemática significativa, lo que nos permite ver de un vistazo qué modelos se desmarcan realmente del resto. Para su generación, se ha empleado la implementación proporcionada por la librería `aeon` [61].

- **Matrices de Comparación Múltiple (MCM):** estas matrices nos permiten hacer una evaluación de “uno contra uno” mucho más al detalle, enfocada especialmente en los modelos estocásticos del estudio que hemos ejecutado 30 veces. Usando el test estadístico de Wilcoxon-Holm, estas gráficas nos confirman mediante colores o p-valores si un modelo es consistentemente superior a su rival a lo largo de todas esas ejecuciones. Esta visualización también ha sido desarrollada integrando las herramientas de la librería `aeon` [61].

6.3.1. Evaluación del acierto puro (CCR y MS)

Comenzando por el análisis estadístico de la tasa de acierto global (CCR), los resultados ratifican lo observado durante todo el análisis. El diagrama de diferencia crítica (CDD) para el CCR (Figura 6.14) sitúa al modelo nominal LightGBM claramente destacado en la primera posición, separado estadísticamente de todos los demás algoritmos, los cuales quedan agrupados por la línea de equivalencia.




Figura 6.14: Diagrama de Diferencia Crítica (CDD) para la métrica CCR.

Esta superioridad matemática queda refrendada al analizar la MCM de la Figura 6.15, donde LightGBM vence a las redes neuronales ordinales (NNPOM y NNOP) y a la Regresión Logística con un p -valor de 0,0078 (altamente significativo). Este comportamiento es totalmente esperable dado el fuerte desbalanceo que presentan los conjuntos de datos: al ignorar el orden y la gravedad de los fallos, los modelos nominales optimizan su función de coste para maximizar el acierto bruto. En la práctica, esto se traduce en favorecer desproporcionadamente a la clase mayoritaria (visibilidad despejada) para inflar su porcentaje de acierto, logrando así la victoria estadística en la métrica CCR.

CAPÍTULO 6. RESULTADOS Y DISCUSIÓN




Figura 6.15: Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en CCR.

Sin embargo, el escenario cambia sustancialmente cuando se evalúa la Sensibilidad Mínima (MS), métrica que refleja la capacidad de los modelos para acertar en la clase más crítica y minoritaria. Al observar el CDD correspondiente a la MS (Figura 6.16), se rompe el dominio del modelo nominal. En este gráfico, la línea de diferencia crítica agrupa en los primeros puestos a LightGBM junto con las dos redes neuronales ordinales (NNOP y NNPO), demostrando que no existe una diferencia estadísticamente significativa entre ellos en cuanto a la detección del caso peor.




Figura 6.16: Diagrama de Diferencia Crítica (CDD) para la métrica MS.

La matriz MCM para la MS (Figura 6.17) nos ayuda a confirmar este comportamiento estocástico: la red ordinal NNOP logra, de hecho, la mejor puntuación media (0,3704), seguida muy de cerca por LightGBM (0,3587) y NNPOM (0,3386). Los p -valores generados por el test de Wilcoxon-Holm entre estos tres algoritmos son mayores a 0,05 (p. ej., $p = 0,8438$ entre NNOP y LightGBM), lo que certifica que las diferencias no son significativas.

Esto demuestra que, aunque los modelos ordinales sacrifiquen parte del acierto global (CCR), logran mantener un nivel de alerta y detección ante situaciones extremas (MS) estadísticamente equivalente e igual de sólido que el mejor de los modelos nominales.

CAPÍTULO 6. RESULTADOS Y DISCUSIÓN




Figura 6.17: Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en MS.

6.3.2. Evaluación de la gravedad del error (AMAE y MMAE)

Para evaluar verdaderamente la reducción del riesgo operativo, es necesario abandonar las métricas nominales y analizar aquellas que penalizan el error en función de la distancia en la escala de visibilidad.

Comenzando por el Error Absoluto Medio Promedio (AMAE), el diagrama CDD (Figura 6.18) muestra un cambio completo respecto al CCR: las redes ordinales NNPOM y NNOP se posicionan como las mejores, relegando a LightGBM al tercer lugar. Sin embargo, la línea gruesa horizontal indica que esta diferencia global no es estadísticamente significativa entre estos tres algoritmos. La matriz MCM estocástica para AMAE (Figura 6.19) corrobora este empate técnico, mostrando p -valores mayores a 0,05 entre ellos, aunque todos superan holgadamente a la Regresión Logística nominal ($p = 0,0078$).




Figura 6.18: Diagrama de Diferencia Crítica (CDD) para la métrica AMAE.




Figura 6.19: Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en AMAE.

El verdadero valor del enfoque ordinal aflora definitivamente al analizar el Error Absoluto Medio Máximo (MMAE), la métrica más restrictiva y que cuantifica la gravedad del peor escenario posible. En el CDD del MMAE (Figura 6.20), la red ordinal NNPOM se sitúa en primera posición de forma aislada frente a los enfoques

nominales, logrando separarse estadísticamente de LightGBM.




Figura 6.20: Diagrama de Diferencia Crítica (CDD) para la métrica MMAE.

Esta superioridad queda demostrada en la matriz MCM de la Figura 6.21. En la evaluación de MMAE, NNPOM logra la puntuación media más baja (0,7449) y vence sistemáticamente al modelo nominal LightGBM de forma altamente significativa ($p = 0,0078$). Resulta destacable, además, que NNPOM logre superar también de forma significativa a la otra red ordinal, NNOP ($p = 0,0391$), posicionándose como el modelo más fiable de todo el estudio.




Figura 6.21: Matriz de Comparación Múltiple (MCM) evaluando los modelos estocásticos en MMAE.

6.3.3. Conclusión del análisis estadístico

En conjunto, estas pruebas estadísticas validan empíricamente la hipótesis principal de este trabajo. Mientras que un enfoque nominal muy potente, como LightGBM, logra obtener unos buenos resultados en CCR apoyándose en el desbalanceo a favor de la visibilidad despejada, lo hace a costa de dejar el sistema vulnerable ante desviaciones graves. Por el contrario, el método ordinal NNPOm proporciona unos resultados estadísticamente superiores para minimizar los peores errores de predicción, convirtiéndola en la opción más robusta y segura para entornos de operatividad crítica como es el tráfico aéreo.

Capítulo 7

Conclusiones y recomendaciones

Este capítulo expone las conclusiones generales derivadas del desarrollo de este Trabajo Fin de Grado, estructuradas de forma directa en relación con los objetivos inicialmente propuestos para la investigación. También, se plantean diversas recomendaciones y líneas de trabajo futuro con el fin de continuar y expandir el estudio de la clasificación ordinal aplicada a la predicción de fenómenos meteorológicos críticos en la aviación.

7.1. Conclusiones

- Sobre el **estudio teórico y la base matemática de la clasificación ordinal**, se ha fundamentado con éxito la necesidad de aplicar esta técnica en la predicción de visibilidad en los aeropuertos, superando las deficiencias de los modelos nominales que ignoran el coste asimétrico de los errores. La revisión del estudio del arte ordinal confirmó que asumir un orden natural en las etiquetas es vital para penalizar las predicciones basadas en su distancia a la clase real.
- Sobre la **obtención y preprocesamiento de los datos de los aeropuertos de Santiago (LEST) y Vigo (LEVX)**, se ha permitido construir un conjunto de datos robusto a partir de la integración y la limpieza de los datos de sensores locales (METAR) y de reanálisis climático (ERA5) de cada uno de estos aeropuertos. El preprocesamiento destacando la codificación cíclica y la extracción de características autorregresivas mediante *lags* y ventanas móviles, ha sido fundamental para transformar datos estáticos en un problema de series temporales enfocado a la predicción futura.
- Sobre la **identificación de las variables más influyentes en la predicción de la visibilidad en aeropuertos**, se ha comprobado que la inercia



temporal (variables autorregresivas de las horas previas) es el factor con mayor correlación lineal para predecir la visibilidad a corto plazo. No obstante, con el estudio de ablación, se ha demostrado que depender únicamente de la memoria temporal provoca ceguera ante cambios meteorológicos bruscos que se puedan producir, haciendo importante el uso de datos de sensores locales (METAR) y de reanálisis climático (ERA5) para reducir los errores más graves.

- Sobre la **implementación y evaluación de distintos métodos**, la evaluación comparativa realizada demuestra que los algoritmos nominales como LightGBM, logran la mayor tasa de acierto global (CCR) debido al gran desbalanceo a favor de las condiciones de visibilidad despejada, pero fallan de forma grave en los errores más críticos. Por el contrario, los métodos ordinales, específicamente la red NNPO, sacrifican una parte marginal de ese acierto global a cambio de reducir de manera destacada los errores más críticos que se pueden producir en el tráfico aéreo.
- Por último, el objetivo principal de toda esta investigación, la **eficacia general de la clasificación ordinal para resolver problemas de visibilidad en aeropuertos**. Tras todo el análisis, se concluye que la clasificación ordinal no solo es una metodología eficaz, sino que representa el enfoque más seguro y viable para resolver el problema de la predicción de baja visibilidad en entornos aeroportuarios. A lo largo de la investigación se ha demostrado el peligro de utilizar modelos nominales de última generación como LightGBM. Aunque estos algoritmos logran los CCR más altos inflando sus resultados por el gran desbalanceo de datos, lo hacen a costa de dejar el sistema predictivo altamente vulnerable ante errores críticos.

En el contexto de la aviación, donde la seguridad es crítica, la clasificación ordinal demuestra su superioridad al integrar el orden natural de las etiquetas, logrando comprimir los fallos que se producen hacia las categorías adyacentes a la etiqueta real. Esto se traduce en la práctica como la eliminación de los “errores más críticos”. Como ejemplo, en el aeropuerto de Santiago (LEST), el enfoque nominal llegó a predecir condiciones de visibilidad despejada en situaciones reales de visibilidad extremadamente baja en un 7,46 % de las ocasiones, un riesgo alto que la metodología ordinal logra reducir hasta un 0,31 %.

En definitiva, el enfoque ordinal sacrifica de forma controlada una parte de su acierto global (CCR) para imponer un orden natural que garantiza una reducción importante de los errores más críticos, proporcionando un modelo más preparado para las exigencias de seguridad que presentan el control del tráfico aéreo.

7.2. Recomendaciones y trabajos futuros

A partir de las limitaciones identificadas y los resultados obtenidos en este proyecto, se proponen las siguientes líneas de investigación para dar continuidad a este trabajo:

- **Ampliación del horizonte temporal de predicción:** dado que el marco experimental de este estudio transforma el problema estático para una predicción inmediata a una hora vista ($t + 1$), puede resultar de gran interés evaluar la robustez de los métodos de clasificación ordinal ante ventanas temporales de mayor incertidumbre, como horizontes de predicción a 3, 6 y 12 horas vista.
- **Inclusión de más variables exógenas locales:** considerando que la formación y evolución de los bancos de niebla están condicionadas por factores orográficos locales de los valles donde se asientan los aeropuertos de Santiago (LEST) y de Vigo (LEVX), se recomienda enriquecer los conjuntos de datos con la inclusión de variables geográficas específicas de los valles donde se ubican LEST y LEVX.
- **Exploración de más modelos ordinales avanzados:** aunque en este trabajo se ha evaluado una selección robusta y representativa de métodos ordinales, el estado del arte en aprendizaje automático se encuentra en continua evolución. Se recomienda profundizar en la búsqueda e implementación de nuevos algoritmos, tales como métodos de *ensemble* ordinales o arquitecturas modernas de aprendizaje profundo adaptadas explícitamente a la clasificación ordinal. Esta línea de investigación permitiría afinar la capacidad de generalización del modelo y optimizar aún más la reducción de los errores graves en este ámbito de la predicción de la visibilidad en aeropuertos.
- **Integración de los modelos en Sistemas de Soporte a la Decisión (DSS, del inglés, *Decision Support System*) operativos:** aunque los entornos aeroportuarios actuales ya disponen de sistemas avanzados de monitorización meteorológica, los algoritmos desarrollados en este trabajo se encuentran en una fase de experimentación y validación *offline*. Como trabajo futuro, a vista de poder mejorar aún más los resultados, se propone encapsular el modelo ordinal NNPOM para integrarlo como un módulo de alerta temprana predictiva dentro de las plataformas de interfaz que ya emplean los controladores aéreos y equipos de operaciones, complementando así las lecturas de los sensores con predicciones a corto plazo altamente seguras.

Bibliografía

- [1] Pedro Antonio Gutiérrez, Maria Perez-Ortiz, Javier Sanchez-Monedero, Francisco Fernandez-Navarro, and Cesar Hervas-Martinez. Ordinal regression methods: survey and experimental study. *IEEE Transactions on Knowledge and Data Engineering*, 28(1):127–146, 2015.
- [2] Sancho Salcedo-Sanz, David Guijo-Rubio, Jorge Pérez-Aracil, César Peláez-Rodríguez, Antonio Manuel Gomez-Orellana, and Pedro Antonio Gutiérrez-Peña. Artificial intelligence-based methods and algorithms in fog and atmospheric low-visibility forecasting. *Atmosphere*, 16(9):1073, 2025.
- [3] Jiawei Han, Micheline Kamber, and Jian Pei. *Data Mining: Concepts and Techniques*. Morgan Kaufmann, 3rd edition, 2011.
- [4] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [6] Trevor Hastie. The elements of statistical learning: data mining, inference, and prediction, 2009.
- [7] Richard S Sutton, Andrew G Barto, et al. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998.
- [8] Agencia Estatal de Meteorología. Asesoramiento meteorológico en los centros de control de área: nuevo servicio aemet. URL <https://aemetblog.es/2022/06/05/asesoramiento-meteorologico-en-los-centros-de-control-de-area-nuevo-servicio-aemet/>.
- [9] Ismail Gultepe, Robert Tardif, Silas C Michaelides, Jan Cermak, Andreas Bott, J Bendix, Mathias David Müller, Mariusz Pagowski, B Hansen, Gary Ellrod, et al. Fog research: A review of past achievements and future perspectives. *Pure and applied geophysics*, 164(6):1121–1159, 2007.

- [10] Haibo He and Edwardo A Garcia. Learning from imbalanced data. *IEEE Transactions on knowledge and data engineering*, 21(9):1263–1284, 2009.
- [11] Tomé Albuquerque, Ricardo Cruz, and Jaime S Cardoso. Ordinal losses for classification of cervical cancer risk. *PeerJ Computer Science*, 7:e457, 2021.
- [12] Zhenxing Niu, Mo Zhou, Le Wang, Xinbo Gao, and Gang Hua. Ordinal regression with multiple output cnn for age estimation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 4920–4928, 2016.
- [13] METAR-TAF. Metar and taf decoder for all 70,898 airports. URL <https://metar-taf.com/>.
- [14] Departamento de Informática y Análisis Numérico de la Universidad de Córdoba. Aprendizaje y redes neuronales artificiales. URL <https://www.uco.es/ayrna/>.
- [15] Sergio Fernández-González, Pedro Bolgiani, Javier Fernández-Villares, Pino González, Alejandro García-Gil, Juan Carlos Suárez, and Andrés Merino. Forecasting of poor visibility episodes in the vicinity of tenerife norte airport. *Atmospheric Research*, 223:49–59, 2019.
- [16] Driss Bari, Thierry Bergot, and Robert Tardif. Fog decision support systems: A review of the current perspectives. *Atmosphere*, 14(8):1314, 2023.
- [17] GJ Steeneveld, RJ Ronda, and AAM Holtslag. The challenge of forecasting the onset and development of radiation fog using mesoscale atmospheric models. *Boundary-Layer Meteorology*, 154(2):265–289, 2015.
- [18] L Cornejo-Bueno, C Casanova-Mateo, J Sanz-Justo, E Cerro-Prada, and S Salcedo-Sanz. Efficient prediction of low-visibility events at airports using machine-learning regression. *Boundary-layer meteorology*, 165(2):349–370, 2017.
- [19] Lei Zhu, Guodong Zhu, Lei Han, Nan Wang, et al. The application of deep learning in airport visibility forecast. *Atmospheric and Climate Sciences*, 7(03):314, 2017.
- [20] Michael C Koziara, Robert J Renard, and William J Thompson. Estimating marine fog probability using a model output statistics scheme. *Monthly weather review*, 111(12):2333–2340, 1983.
- [21] Paul M Tag and James E Peak. Machine learning of maritime fog forecast rules. *Journal of Applied Meteorology and Climatology*, 35(5):714–724, 1996.



- [22] Dustin Fabbian, Richard De Dear, and Stephen Lelleyett. Application of artificial neural network forecasts to predict fog at canberra international airport. *Weather and forecasting*, 22(2):372–381, 2007.
- [23] Caren Marzban, Stephen Leyton, and Brad Colman. Ceiling and visibility forecasts via neural networks. *Weather and forecasting*, 22(3):466–479, 2007.
- [24] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794, 2016.
- [25] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. Lightgbm: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 30, 2017.
- [26] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [27] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- [28] Carlos Castillo-Botón, David Casillas-Pérez, Carlos Casanova-Mateo, Sujana Ghimire, Elena Cerro-Prada, Pedro A Gutierrez, Ravinesh C Deo, and Sancho Salcedo-Sanz. Machine learning regression and classification methods for fog events prediction. *Atmospheric Research*, 272:106157, 2022.
- [29] Piyush Teeloku, Zheqi Chen, Peter Taylor, and Yongsheng Chen. Weather research and forecasting (wrf) model and machine learning algorithms to improve marine fog predictions at two coastal locations in atlantic canada. *Atmosphere-Ocean*, pages 1–19, 2026.
- [30] Topon Paul, Vidhisha Reddy, Sai Prem Kumar Ayyagari, Ryusei Shingaki, and Kaneharu Nishino. Forecasting of low visibility using weather and air quality data for safe and smooth transportation operation. In *2024 International Conference on Machine Learning and Applications (ICMLA)*, pages 918–923. IEEE, 2024.
- [31] Stefan Kramer, Gerhard Widmer, Bernhard Pfahringer, and Michael De Groeve. Prediction of ordinal classes using regression trees. *Fundamenta Informaticae*, 47(1-2):1–13, 2001.

- [32] Edward F Harrington. Online ranking/collaborative filtering using the perceptron algorithm. In *Proceedings of the 20th International Conference on Machine Learning (ICML-03)*, pages 250–257, 2003.
- [33] Sotiris B Kotsiantis and Panagiotis E Pintelas. A cost sensitive technique for ordinal classification problems. In *Hellenic Conference on Artificial Intelligence*, pages 220–229. Springer, 2004.
- [34] Hsuan-Tien Lin and Ling Li. Reduction from cost-sensitive ordinal ranking to weighted binary classification. *Neural Computation*, 24(5):1329–1367, 2012.
- [35] Eibe Frank and Mark Hall. A simple approach to ordinal classification. In *European conference on machine learning*, pages 145–156. Springer, 2001.
- [36] Jan Verwaeren, Willem Waegeman, and Bernard De Baets. Learning partial ordinal class memberships with kernel-based proportional odds models. *Computational Statistics & Data Analysis*, 56(4):928–942, 2012.
- [37] Peter McCullagh. Regression models for ordinal data. *Journal of the Royal Statistical Society: Series B (Methodological)*, 42(2):109–127, 1980.
- [38] Wei Chu and S Sathya Keerthi. Support vector ordinal regression. *Neural computation*, 19(3):792–815, 2007.
- [39] Riccardo Rosati, Luca Romeo, Víctor Manuel Vargas, Pedro Antonio Gutiérrez, César Hervás-Martínez, and Emanuele Frontoni. A novel deep ordinal classification approach for aesthetic quality control classification. *Neural Computing and Applications*, 34(14):11625–11639, 2022.
- [40] Juan Carlos Fernández Caballero, Francisco José Martínez, César Hervás, and Pedro Antonio Gutiérrez. Sensitivity versus accuracy in multiclass problems using memetic pareto evolutionary neural networks. *IEEE Transactions on Neural Networks*, 21(5):750–770, 2010.
- [41] Kay Henning Brodersen, Cheng Soon Ong, Klaas Enno Stephan, and Joachim M Buhmann. The balanced accuracy and its posterior distribution. In *2010 20th international conference on pattern recognition*, pages 3121–3124. IEEE, 2010.
- [42] Stefano Baccianella, Andrea Esuli, and Fabrizio Sebastiani. Evaluation measures for ordinal regression. In *2009 Ninth international conference on intelligent systems design and applications*, pages 283–287. IEEE, 2009.



- [43] Victor M Vargas, Antonio M Gomez-Orellana, Pedro A Gutierrez, Cesar Hervas-Martinez, and David Guijo-Rubio. Ebano: A novel ensemble based on unimodal ordinal classifiers for the prediction of significant wave height. *Knowledge-Based Systems*, 300:112223, 2024.
- [44] Antonio M Gomez-Orellana, David Guijo-Rubio, Pedro A Gutierrez, Cesar Hervas-Martinez, and Victor M Vargas. Orfeo: Ordinal classifier and regressor fusion for estimating an ordinal categorical target. *Engineering Applications of Artificial Intelligence*, 133:108462, 2024.
- [45] Jordi de La Torre, Domenec Puig, and Aida Valls. Weighted kappa loss function for multi-class classification of ordinal data in deep learning. *Pattern Recognition Letters*, 105:144–154, 2018.
- [46] Python Software Foundation. Welcome to python.org, 2026. URL <https://python.org>.
- [47] The pandas development team. pandas: powerful python data analysis toolkit, 2026. URL <https://pandas.pydata.org/>.
- [48] NumPy Developers. Numpy: the absolute base for scientific computing with python, 2026. URL <https://numpy.org/>.
- [49] Joaquin Amat Rodrigo and Javier Escobar Ortiz. Welcome to skforecast - documentación oficial, s.f. URL <https://skforecast.org/>.
- [50] Scikit-learn developers. scikit-learn: machine learning in python, 2025. URL <https://scikit-learn.org/stable/index.html>.
- [51] LightGBM Contributors. Lightgbm documentation, 2026. URL <https://lightgbm.readthedocs.io/en/stable/>.
- [52] Javier Sánchez-Monedero, Pedro A Gutiérrez, and María Pérez-Ortiz. Orca: A matlab/octave toolbox for ordinal regression. *Journal of Machine Learning Research*, 20(125):1–5, 2019.
- [53] AYRNA Research Group. skordinal: Framework migration project from matlab to python, 2026. URL <https://github.com/ayrna/skordinal>. GitHub repository.
- [54] Fabian Pedregosa. mord: ordinal regression in python, 2018. URL <https://github.com/fabianp/mord>. GitHub repository.
- [55] Grupo AYRNA. dlordinal: Deep learning for ordinal regression. <https://github.com/ayrna/dlordinal>, 2026. GitHub Repository.

- [56] Joblib Development Team. joblib: Running python functions as pipeline jobs, 2026. URL <https://joblib.readthedocs.io>.
- [57] Casper O da Costa-Luis. tqdm: A fast, extensible progress meter for python and cli. *Journal of Open Source Software*, 4(37):1277, 2019.
- [58] Grupo AYRNA. remayn. <https://github.com/ayrna/remayn>, 2026. GitHub Repository.
- [59] The Matplotlib Development Team. Matplotlib: Visualization with python, 2026. URL <https://matplotlib.org/>.
- [60] Michael L Waskom. Seaborn: statistical data visualization. *Journal of open source software*, 6(60):3021, 2021.
- [61] Matthew Middlehurst, Ali Ismail-Fawaz, Antoine Guillaume, Christopher Holder, David Guijo-Rubio, Guzal Bulatova, Leonidas Tsaprounis, Lukasz Mentel, Martin Walter, Patrick Schäfer, et al. aeon: a python toolkit for learning from time series. *Journal of Machine Learning Research*, 25(289):1–10, 2024.
- [62] METAR-TAF.com. Explicación de metar y taf. <https://metar-taf.com/es/explanation>, s.f.
- [63] Ogimet. Búsqueda de metar/speci, s.f. URL <https://www.ogimet.com/metars.phtml>.
- [64] Copernicus Climate Change Service. Era5 hourly data on single levels from 1940 to present, s.f. URL <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels?tab=overview>.
- [65] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(4):1–21, 2012.
- [66] Vitor Cerqueira, Luis Torgo, and Igor Mozetič. Evaluating time series forecasting models: An empirical study on performance estimation methods. *Machine Learning*, 109(11):1997–2028, 2020.
- [67] Rob J Hyndman and George Athanasopoulos. *Forecasting: principles and practice*. OTexts, 2018.
- [68] Aaron Defazio, Francis Bach, and Simon Lacoste-Julien. Saga: A fast incremental gradient method with support for non-strongly convex composite objectives. *Advances in neural information processing systems*, 27, 2014.

BIBLIOGRAFÍA

- [69] Jianlin Cheng, Zheng Wang, and Gianluca Pollastri. A neural network approach to ordinal regression. In *2008 IEEE international joint conference on neural networks (IEEE world congress on computational intelligence)*, pages 1279–1284. IEEE, 2008.
- [70] Mark J Mathieson. Ordinal models for neural networks. In *Proceedings of the Third International Conference on Neural Networks in the Capital Markets*, pages 523–536. World Scientific, 1996.
- [71] Richard Meyes, Melanie Lu, Constantin Waubert De Puiseau, and Tobias Meisen. Ablation studies in artificial neural networks. *arXiv preprint arXiv:1901.08644*, 2019.
- [72] Xavier Bouthillier, Pierre Delaunay, Mirko Bronzi, Assya Trofimov, Brennan Nichyporuk, Justin Szeto, Nazanin Mohammadi Sepahvand, Edward Raff, Kanika Madan, Vikram Voleti, et al. Accounting for variance in machine learning benchmarks. *Proceedings of machine learning and systems*, 3:747–769, 2021.